Statistiques appliquées sous R

« Il y a trois sortes de mensonges : les mensonges, les sacrés mensonges et les statistiques. »

Mark Twain

But du module : ne pas mentir avec les statistiques, et savoir détecter les mensonges

I. POURQUOI LES STATISTIQUES ?

I. BUT DES STATISTIQUES

Définition de la problématique

Examen de l'état des connaissances

Détermination des hypothèses de travail

Choix

Choix du matériel, des sujets …

Choix de l'approche

des variables :
qui est mesuré

dispositifs de mesure

echantillonnage

des estimateurs et des analyses

de la méthode

Démarche à intégrer tout au début de la réflexion dans les protocoles

BUT 1

Gérer la variabilité des mesures : hasard ou phénomène sous-jacent ???

Variabilité

Interprétation

Conclusions

Sir Ronald Fisher
1890-1962

- *To consult the statistician after an experiment is finished is often merely to ask him to conduct a post mortem examination. He can perhaps say what the experiment died of.*

TABLEAUX DE DONNÉES : pas toujours faciles à lire et comprendre

On remarque que chaque colonne est une VARIABLES

Code	Season	Lake	X10Me16.0	X11.00	X12.00	X13.00	X14.00	X14.0iso	X15.00	X15.0anteiso	X1[illegible]iso	X15.01	X16.00	X16.0iso	X16.1w5	X16.1w7	X16.1w9
1	505a	HW	Cabaliana	0.61771304		0	3.074346741	0.516604	6.687415084	0.862586496	2.481910961	[illegible]93766	1.734651964	0	24.82858858	0.443931878	1.093241495	8.385730987
2	505b	HW	Cabaliana	0.684897919		0	2.804975726	0.475668961	6.438694281	0.9235497	2.510747[illegible]	[illegible]701276[illegible]	1.88632983	0	26.05554375	0.459322948	1.142586266	9.534629027
3	505c	HW	Cabaliana	0.655395951		0	3.498300825	0.446925779	6.701030928	0.856726733	2.7001[illegible]	[illegible]964074[illegible]	1.873375789	0	23.65708085	0.536882086	1.229402861	8.935659822
4	509a	HW	[illegible]uaca	0	0	2.989094358	0.7769[illegible]	8.913545124	1.327011222	4.69[illegible]	[illegible]8119172	2.317053896	0.921763869	27.92223803	0.972340762	0	7.267899478
5	509b	HW	Jana[illegible]	0	0	1.860126569	0.6618[illegible]	[illegible]383219771	1.060137353	4[illegible]	[illegible]1624173[illegible]	2.205867486	0.646326587	25.64683206	0.775052737	0	8.598367672
6	509c	HW	Janauac[illegible]	0	0	0.411495882	0.386[illegible]	[illegible]820508	0.39589414[illegible]	[illegible]	[illegible]5506764	1.783798894	0.556462046	28.59798868	0.740432558	0	9.147169909
7	512a	HW	Janauaca		0	2.052323186	0.69[illegible]	[illegible]5637	0.78997[illegible]	[illegible]	[illegible]4524558[illegible]	1.574921857	0	28.667196	0.43317889	0	8.883684935
8	512b	HW	Janauaca		0	2.395024291	0.6[illegible]	[illegible]8	0.821[illegible]	[illegible]	[illegible]385173[illegible]	[illegible]	0	30.24414395	0.416705346	0	8.161854958
9	512c	HW	Janauaca			[illegible]87497701	0[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	0	29.97009678	0.431829255	0	8.552512157
10	513a	HW	Janauaca	0.581262[illegible]		[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]327534858	24.54082631	0.592109452	1.494539907	11.60449635
11	513b	HW	Janauaca	0.651931718		[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible] 0.225953607	23.97530182	0.622868325	1.864330958	13.59739227
12	513c	HW	Janauaca	0.73179536		[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible] 0.497708354	25.38203218	0.572455762	1.760392624	13.03813576
13	519a	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	0.538666894	0	3.655442859
14	519b	HW	[illegible]			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]0.415276659	0	5.158684824
15	519c	HW	[illegible]			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]423696	0.346069888	0	5.032506907
16	520a	HW	Mira[illegible]			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	26.83473177	0.793500133	0	5.713960287
17	520b	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]876325	26.35335689	0.939929329	0	7.176678445
18	520c	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]2721	27.39462533	1.076048171	0	5.67573595
19	522a	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]1	6353755[illegible]	0.423193952	0	5.700827786
20	522b	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]7029	0.53421461		0	6.73394691
21	522c	HW	Miratuba			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	0.635706377	0	9.366247639
22	525a	HW	Canacari			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]6	0.330473336	[illegible]9302	0	6.989203169
23	525b	HW	Can[illegible]			[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]1	0.733154671	23.30781011	0.754211332	0	6.227029096
24	525c	HW	[illegible]	0		0[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]0.698257226	22.98318444	0.516519044	0	6.973007097
25	526a	HW	Canacari	0		[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible].179[illegible]	[illegible]	[illegible]994743758	26.62549277	0.423784494	0	5.990144547
26	526b	HW	Canacari	0		[illegible]	[illegible]	[illegible]	[illegible]9 0.[illegible]	[illegible]	[illegible]0.7697468[illegible]	[illegible]	[illegible]73766715	27.6671989	0.433762762	0	7.877943112
27	526c	HW	Canacari	0		[illegible]	[illegible]0.50[illegible]	[illegible]	[illegible]19 0.28[illegible]	[illegible]	[illegible]0.883571405	[illegible]	[illegible]088788	28.82179432	0.606502502	0	8.446624466
28	527a	HW	Canacari	0		[illegible]430325	0.26[illegible]	[illegible]518	1.0467[illegible]	[illegible]	[illegible]0.528956789	1.5820[illegible]	[illegible]	0	28.98395551	0.361160828	0	10.94509077
29	527b	HW	Canacari	0		[illegible] 0.500345261	0.246[illegible]	[illegible]9549	0.9735224[illegible]	[illegible]	[illegible]6 0.622601569	1.193131007	[illegible]	0	27.11373233	0.375824947	0	9.258651332
30	527c	HW	Canacari	0		0 1.305422115	0.314[illegible]	[illegible]68138	1.07848439[illegible]	[illegible]	[illegible]71 0.687175898	1.326631247	[illegible]	0	25.03419973	0.42842448	0	8.694683931

BUT 2

Gérer des tableaux de données souvent inutilisables autrement

II. QU’EST-CE QU’UNE VARIABLE ?

Notion de variable

Les variables sont :

Ce que vous mesurez :

- « Mesure »
- « Variable dépendante »

Les variables peuvent aussi être les paramètres influençant ce que vous mesurez :

- « Variable indépendante »
- « Facteurs »
- « Paramètres »

EXEMPLES :

Mesure : Pluviométrie	*Mesure : Note*	*Mesure : Survie des insectes*
Facteur : Saison	*Facteur : Module*	*Facteur : Taux d'insecticides*

Elles sont de différentes natures :

Ordinal { QUANTITATIVES CONTINUES, QUANTITATIVES DISCRÈTES, QUALITATIVES ORDINALES, QUALITATIVES NOMINALES } Discret

Les variables qualitatives ordinales sont parfois appelées « semi-quantitatives ».
Quand un facteur est discret, ses différentes valeurs sont appelées **niveaux**.

Exercice :
Quelle est la nature de ces variables ?

- Comportement de peur
- Couleur (évalué à l'œil)
- Couleur (longueur d'onde)

Effet du choix de la mesure

- Taille en mm
- Pointure (chaussure) Exemple de discrétisation
- Réponse vs. Non-réponse
- Orientation
- Bactéries en suspension
- Notes
- Résultat d'un lancer de dé
- A RETENIR : importance du choix de la mesure

III. POPULATIONS ET ÉCHANTILLONS

Les expériences et les mesures sont pratiquement toujours faites sur des échantillons

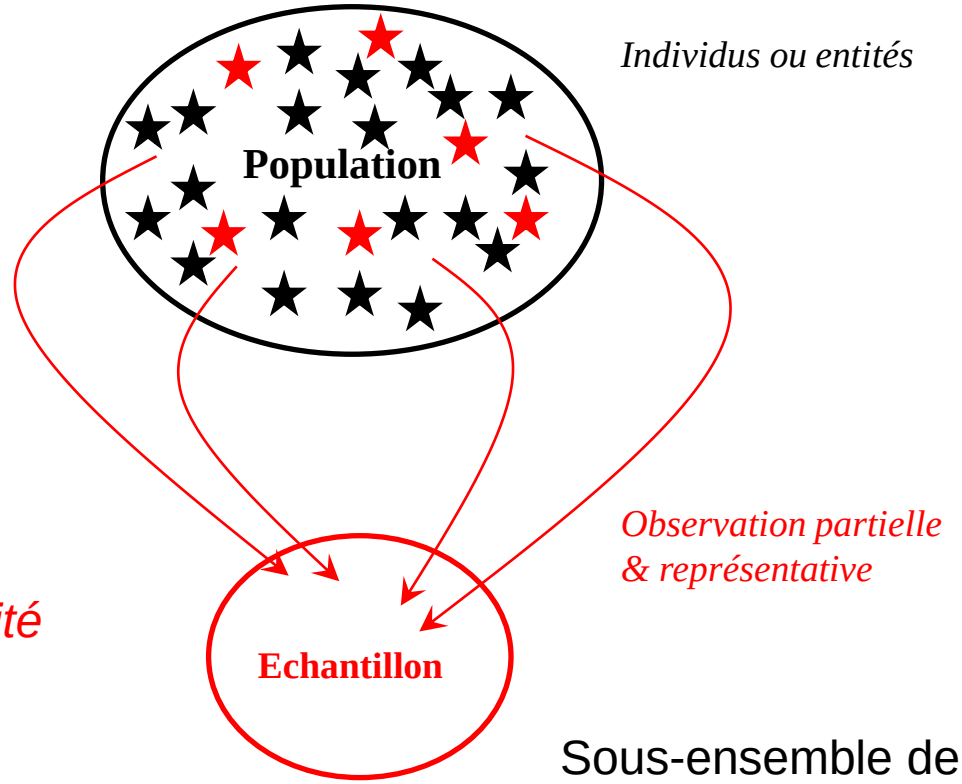

Variabilité

Sous-ensemble de la population

- Importance du plan d'échantillonnage
- Prédiction pour la population à partir des observations d'un ou plusieurs échantillons
- Statistiques : caractérisation de ces prédictions, notamment leurs imprécisions

Les risques liés à l'échantillonnage

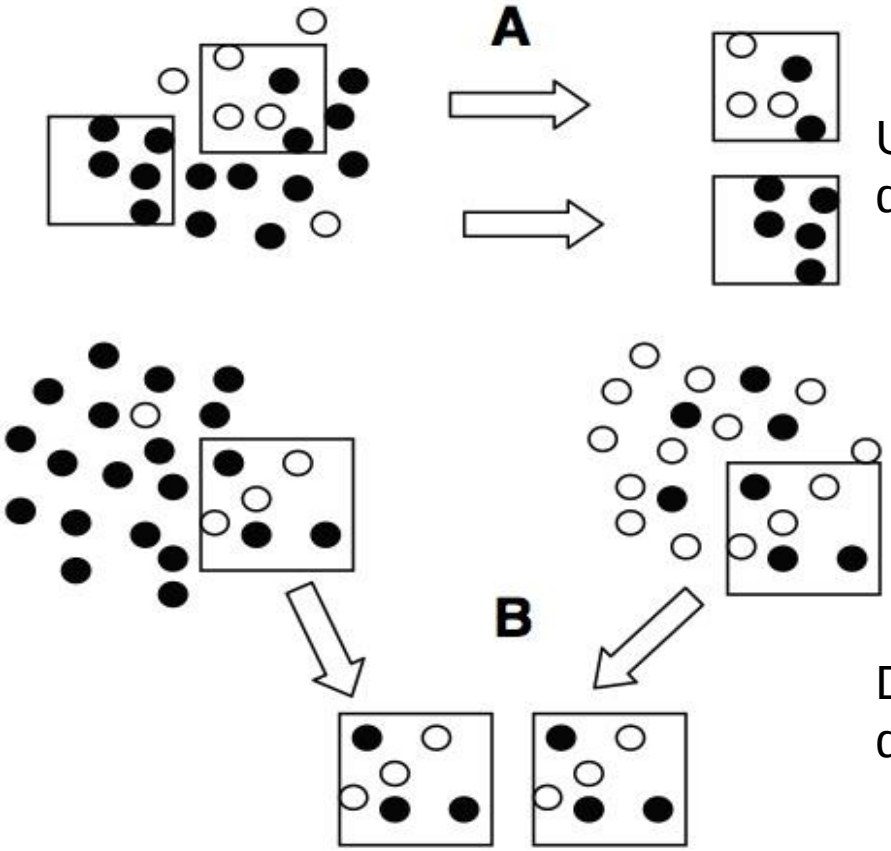

Une population peut donner des échantillons variables

Deux populations peuvent donner des échantillons semblables

Figure 1.1 Les méfaits des fluctuations d'échantillonnage. A: Deux échantillons, même fort différents, ne proviennent pas nécessairement de deux populations différentes. **B** : Deux échantillons, même fort semblables, ne proviennent pas nécessairement de deux populations semblables.

Mesures indépendantes et appariées

- Si on a plusieurs échantillons où on mesure les mêmes choses
  - Exemple : groupe traitement, groupe contrôle
  - Si les mesures n'ont aucune relations, les groupes sont indépendants
  - Si chaque individu appartient aux deux groupes, les groupes sont dits appariés
  - Si les mêmes individus sont mesurés plusieurs fois au sein d'un même groupe, c'est une mauvaise pratique expérimentale appelée pseudo-réplication

- Exercice : dire si ces groupes sont indépendants ou appariés
  - On a mesuré la pluviométrie dans différents lieux en juin puis en septembre
  - On compare le coefficient de marée le 15 juin dans plusieurs sites de la Mer Méditerranée et de la Mer Rouge
  - On mesure la rapidité d'animaux avant et après une intoxication
  - On compare la longueur des fémurs droit et gauche d'une série de fossiles
    - On veut comparer toutes les mesures (les droites et le gauches) à une seule valeur théorique (il y a un piège !)
    - On veut tester l'existence d'une différence droite/gauche (latéralisation)
  - On compare les indices de diversité mesurés dans différentes zones à différents étages d'une même montagne

Principe sous-jacent : les probabilités

Population (la réalité)
Variable à étudier
Rattachée à une distribution de valeurs possible, la loi de

Raisonnement de base des statistiques

Ce qui est fait en pratique

Théorie de l'estimation / inférence :
« J'ai lancé 20 fois un dé et fait 18 fois 6, est-il pipé ? » (induction)

Théorie de l'échantillonnage :
« Je lance un dé, probabilité de faire un 6 »

Échantillon (ce qu'on a)
- Décrire la population : statistiques descriptives
- Comparer des populations : statistiques inférentielles

Les deux objectifs vus au début

Principe sous-jacent : les probabilités

- On a besoin d'utiliser des probabilités : c'est l'outil mathématique sous-jacent.

- Le plus souvent, ces probabilités sont déterminées en employant des lois, par exemple la loi normale (ou loi de Gauss, ou de Laplace-Gauss).

- Toutes les lois peuvent être décrites avec des paramètres.

Les principaux paramètres caractéristiques d'une distribution

Paramètres de position :

ils permettent de situer une série de valeurs

la moyenne (uniquement pour les données quantitatives)
la médiane
le mode (la ou les valeurs les plus fréquentes,
seul possible pour les données nominales)

Paramètres de dispersion :

ils permettent de visualiser la dispersion des valeurs d'une série

la variance
l'écart-type
le minimum et le maximum
l'intervalle inter-quartile
l'amplitude (maximum – minimum)

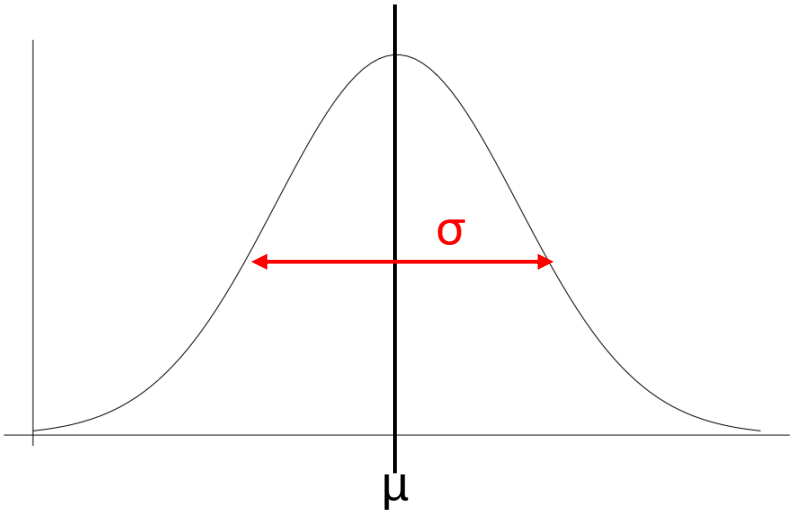

Variance et mesure de la dispersion autour de la moyenne

	X	x-moyenne		(x-moyenne)²
x1	1	1-3 =	-2	4
	2	2-3 =	-1	1
	3	3-3 =	0	0
	4	4-3 =	1	1
x5	5	5-3 =	2	4
Somme	15	Somme =	0	Somme = 10
Moyenne	3			

Si on mesure l'écart à la moyenne un problème se pose :

Centrage sur la moyenne
La somme est TOUJOURS
Égale à 0

On règle le problème avec
La SOMME DES CARRES DES
ECARTS : SCE

La SCE va permettre de calculer la variance.

La ***variance*** est donnée par : $\sigma^2 = \frac{\overbrace{\boxed{\sum_{i=1}^{n} (x_i - \mu)^2}}^{\text{SCE}}}{n}$

L'écart type σ est la racine carrée de la variance (pour être dans la même unité que la moyenne)
En anglais : standard deviation

Attention : La formule de la variance donnée ici n'est valable qu'en situation descriptive, dans laquelle toute la population étudiée est observée (**n étant ici l'effectif de la population**).

Nous verrons plus loin que son estimation dans un échantillon donnera une expression similaire au dénominateur près (n-1 au lieu de n, avec **n effectif de l'échantillon**).

Médiane

La médiane est la valeur telle qu'il y ait autant de valeurs supérieures et inférieures à cette valeur (généralisable à d'autres divisions, ex : les **quartiles** pour 25%/75% et 75%/25%).

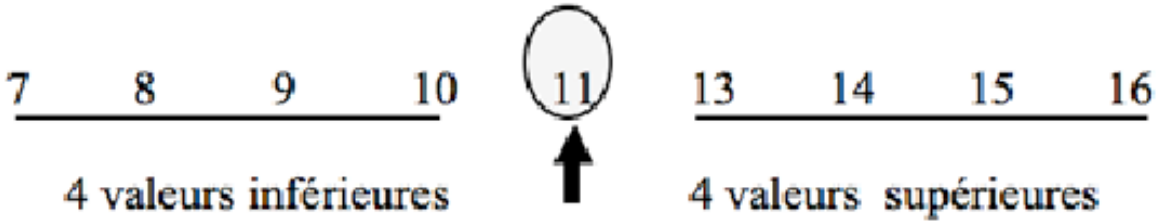

- Pour un nombre impair de valeurs, la médiane est la valeur centrale.
- Pour un nombre pair, c'est la moyenne des deux valeurs centrales.
- Quand les données sont continues ou données par intervalle, c'est la valeur en deçà de laquelle on a 50% des données ordonnées de la plus petite à la plus grande.
- Important : la médiane est beaucoup moins sensible que la moyenne aux valeurs extrêmes. Exemple : salaire moyen (2250€) vs. salaire médian (1797€, Insee 2015)
- Moyenne = centre de gravité ; médiane = milieu

Graphiques des distributions : boxplot (ou boite à moustache) et histogramme

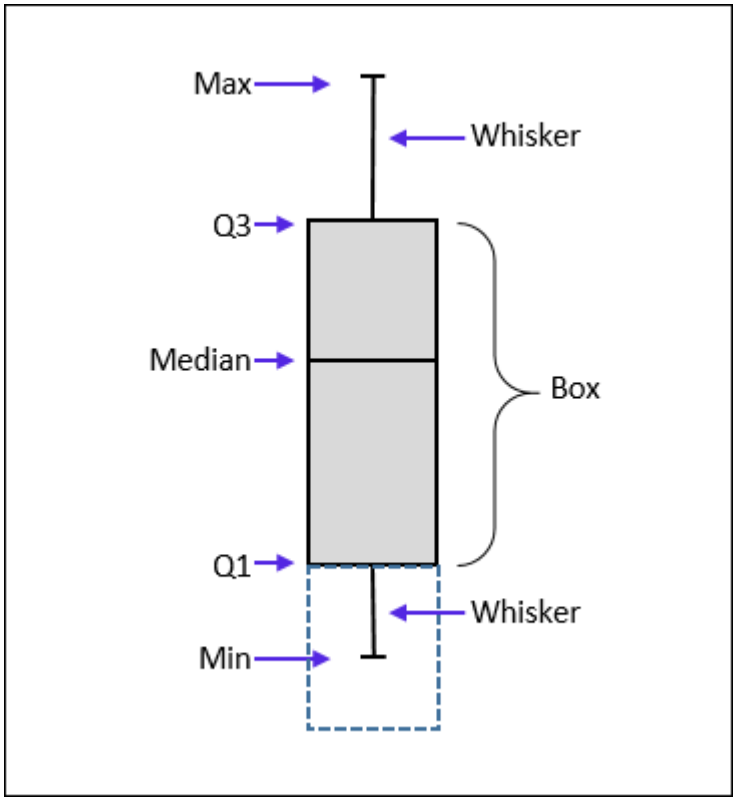

Boxplot

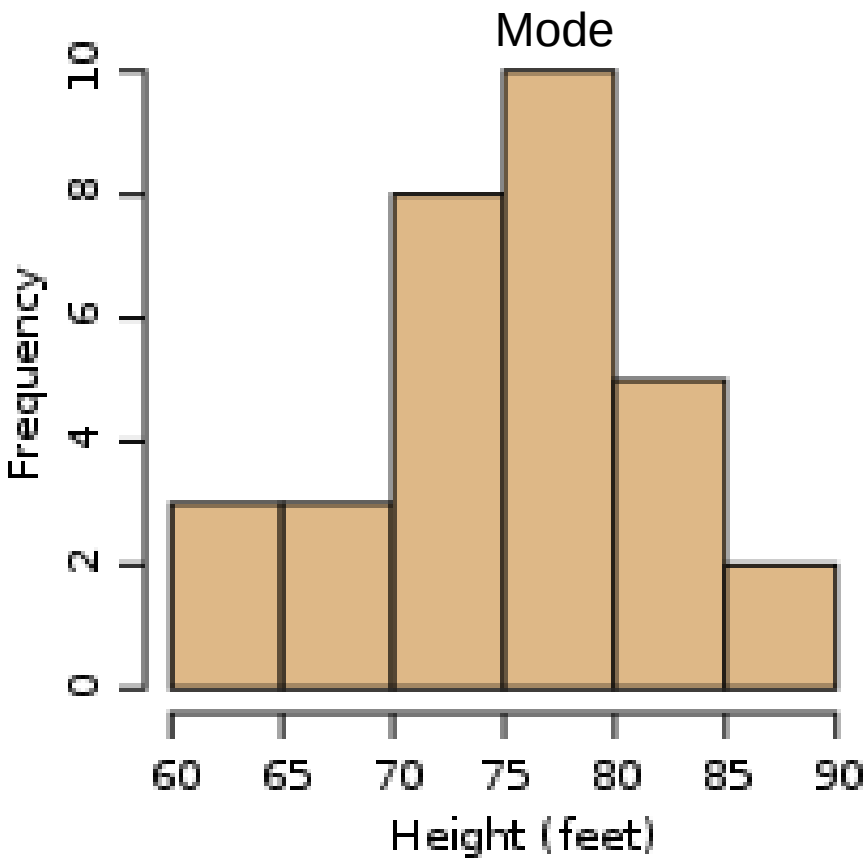

Histogramme à 6 classes

Attention aux résumés numériques et graphiques

- Voici une série de nuages de points (le datasaurus)
  - Les données en x et en y ont les mêmes moyennes et écart type à chaque fois

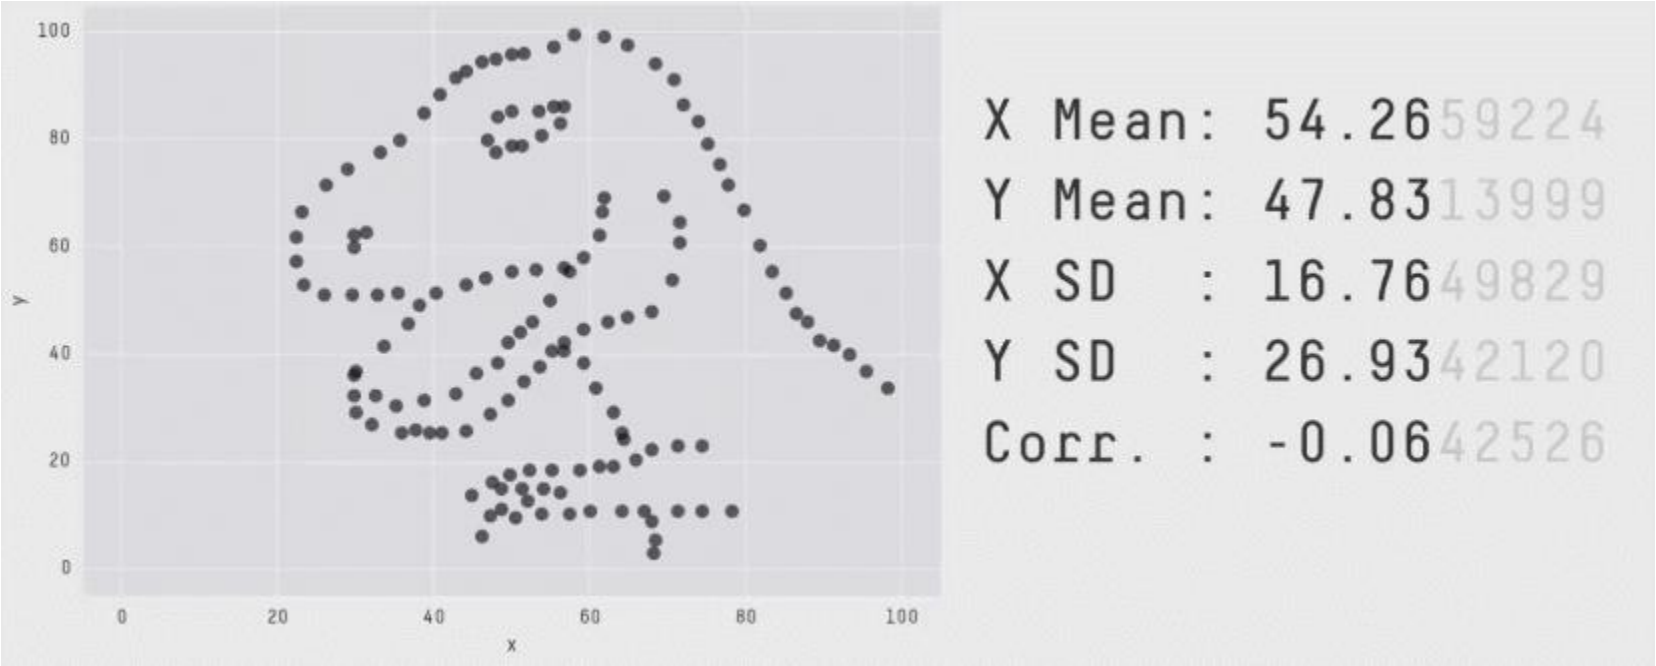

- Regarder l'histogramme et le nuage de points est toujours une bonne idée

Attention aux résumés numériques et graphiques

- Deuxième exemple : même box-plot, distribution différente

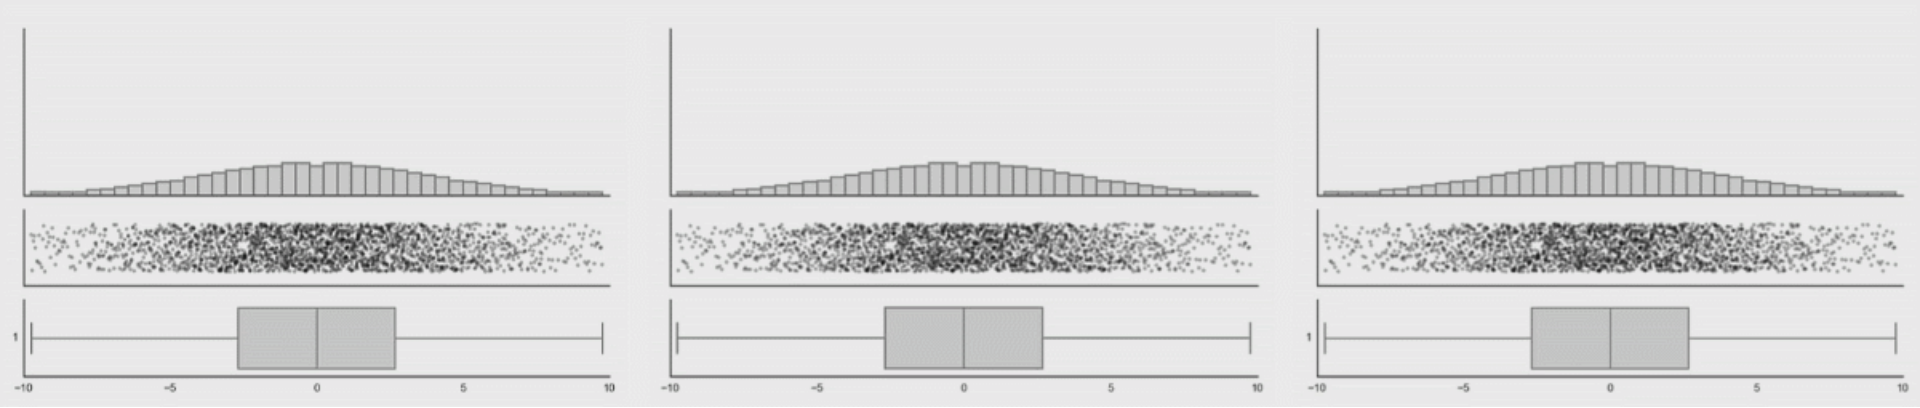

- Regarder l’histogramme et le nuage de points est toujours une bonne idée

IV. INFÉRENCES SUR UNE POPULATION A PARTIR D'UN ÉCHANTILLON

Rappel de notre situation

Population (la réalité)

Ce qu'on cherche à faire !!!

<u>Théorie de l'estimation / inférence :</u>
« J'ai lancé 20 fois un dé et fait 18 fois 6, est-il pipé ? »

Échantillon (ce qu'on a)

1) Comment estimer la moyenne et la variance ?

« Ayant un échantillon, peut on estimer (c'est-à-dire prévoir) la moyenne μ et la variance σ^2 de la population ? »

OUI !!!

	POPULATION	ÉCHANTILLON
MOYENNE	μ	$\bar{x}$
VARIANCE	σ^2	s^2 est mauvais $\widehat{\sigma^2}$ est le bon estimateur

Attention à la variance : appliquer la formule vue précédemment $s^2 = \frac{SCE}{n}$ n'estime par correctement σ^2, il faut prendre $\widehat{\sigma^2} = \frac{SCE}{n-1}$; on note $\hat{\sigma}$ l'estimateur de l'écart type

En résumé : nous pouvons prévoir que la moyenne de la population est *environ* $\bar{x}$ (calculée comme d'habitude), et que la variance de la population est *environ* $\widehat{\sigma^2}$

Est-ce suffisant ?
NON !!! Le « environ » est trop vague, il faut quantifier cette imprécision.

2) Peut-on quantifier la précision de notre estimation ?

OUI !!! La précision, ou plus correctement l'imprécision avec laquelle la moyenne est estimée s'appelle **l'erreur standard de la moyenne** :

$$\frac{\sigma}{\sqrt{n}}, \text{ soit en pratique : } \frac{\hat{\sigma}}{\sqrt{n}}$$

où n est la taille de l'échantillon. Cela veut dire que plus l'échantillon est grand (n élevé) et moins il est dispersé (écart type faible), mieux la moyenne réelle sera estimée.

On s'en sert fréquemment pour représenter graphiquement des moyennes.

Il existe une erreur standard de la variance, mais elle n'a qu'un intérêt théorique.

En anglais, ne pas confondre standard deviation (écart type) et standard error !

Exemple de diagramme en bâton

Une barre d'erreur correspondant à l'erreur standard est ajoutée

Elle permet de voir que le traitement 2 semble différer du contrôle, tandis que pour le traitement 1 la marge d'erreur est trop importante pour conclure

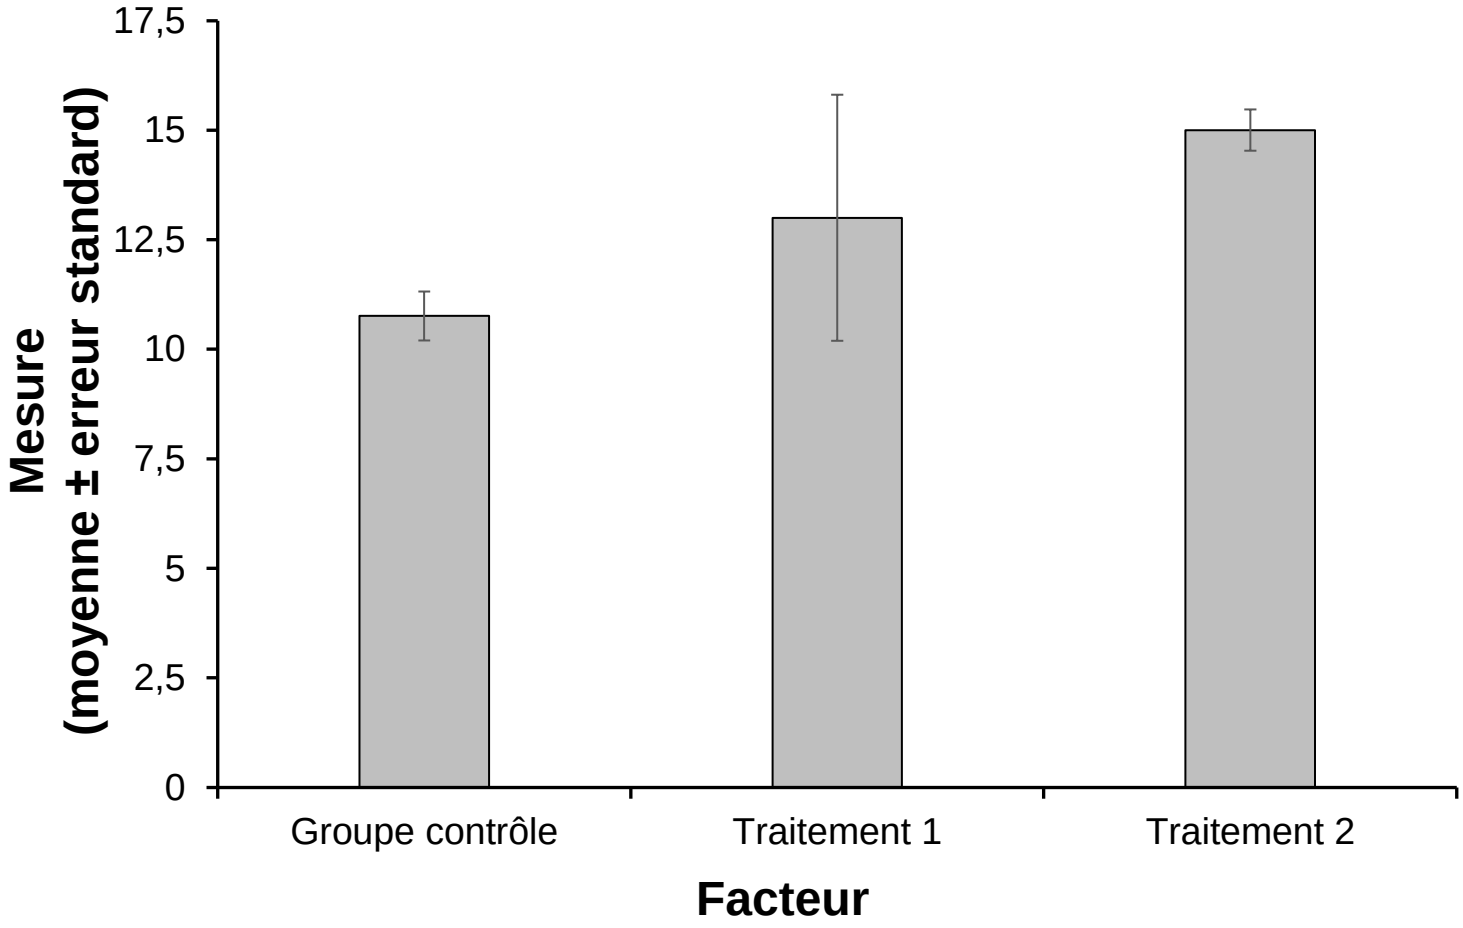

3) Signification de l'erreur standard

Théorème central limite :

- Si on prend des échantillons de taille n suffisamment importante (en théorie infinie, en pratique au moins 30) dans une population quelconque de moyenne μ et d'écart type σ …
- … alors les moyennes $\bar{x}$ de ces échantillons seront distribuées selon un loi de probabilité nommée loi normale (aussi appelée loi gaussienne ou loi de Laplace-Gauss). Ceci est vrai quelle que soit la population considérée.

N'importe quelle population…

… échantillons de taille n ≥ 30 …

… la population des $\bar{x}$ des échantillons suit une loi normale

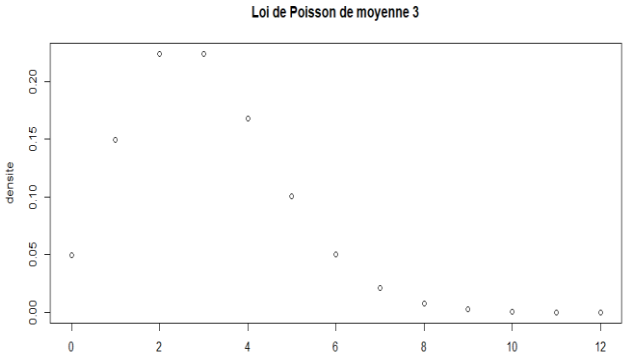

Echantillon 1, de moyenne $\overline{x_1}$

Echantillon 2, de moyenne $\overline{x_2}$

Echantillon 3, de moyenne $\overline{x_3}$

Echantillon 4, de moyenne $\overline{x_4}$

Echantillon *i*, de moyenne $\overline{x_i}$

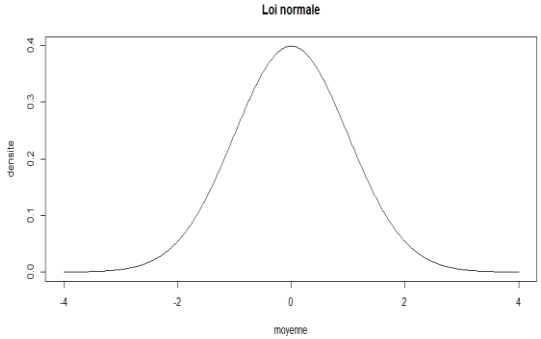

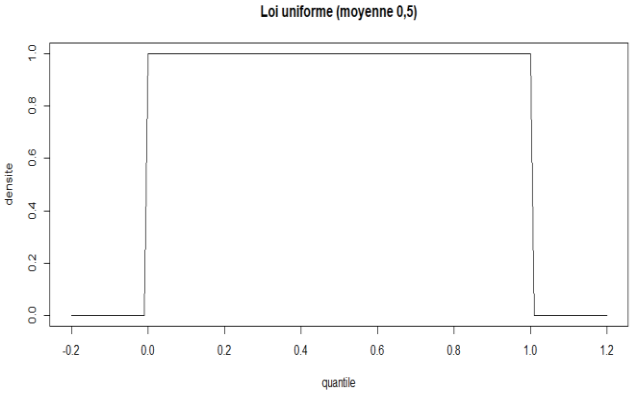

Echantillon 1, de moyenne $\overline{x_1}$

Echantillon 2, de moyenne $\overline{x_2}$

Echantillon 3, de moyenne $\overline{x_3}$

Echantillon 4, de moyenne $\overline{x_4}$

Echantillon *i*, de moyenne $\overline{x_i}$

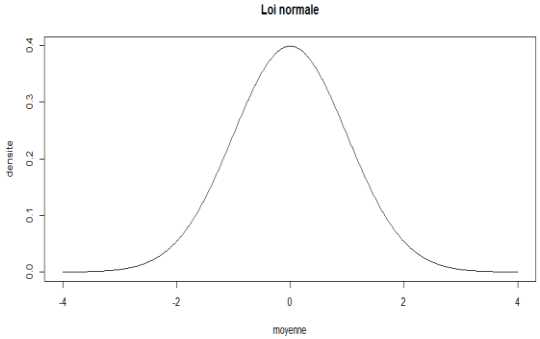

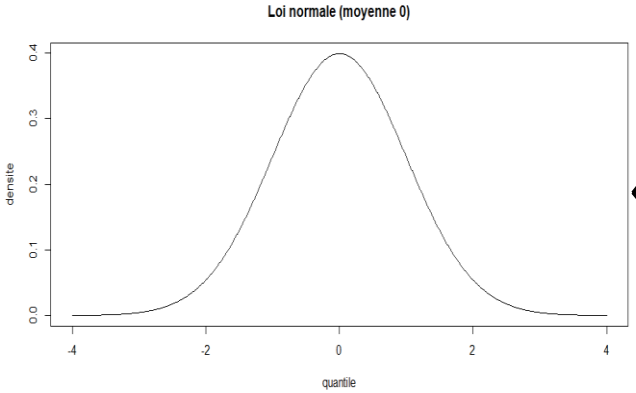

Echantillon 1, de moyenne $\overline{x_1}$

Echantillon 2, de moyenne $\overline{x_2}$

Echantillon 3, de moyenne $\overline{x_3}$

Echantillon 4, de moyenne $\overline{x_4}$

Echantillon *i*, de moyenne $\overline{x_i}$

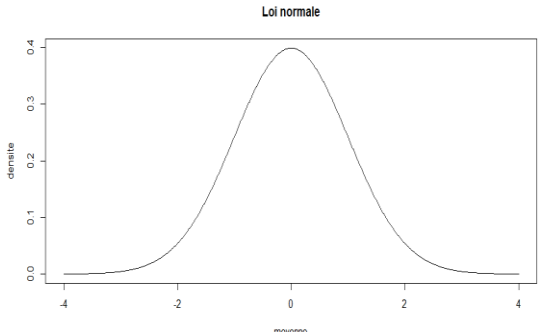

3) Signification de l'erreur standard

Théorème central limite :

- La loi normale donnant la distribution des moyennes $\bar{x}$ aura pour moyenne μ et pour écart type $\sigma/\sqrt{n}$ c'est-à-dire **l'erreur standard de la moyenne**.
- Astuce : en posant σ = $\hat{\sigma}$, un seul échantillon suffit pour connaitre la loi ! Cela correspond à la réalité expérimentale.

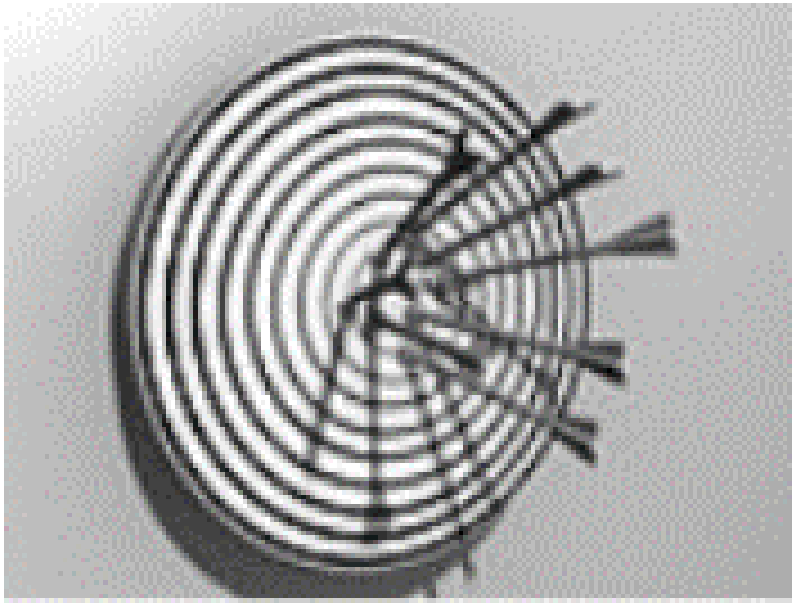

Cible = toutes les moyennes d'échantillons possibles, en vertu du théorème central limite
Centre de la cible = μ
Chaque flèche = la moyenne d'un échantillon (parmi tout ceux possibles)
Distribution des flèches = loi normale
Dispersion des flèche proportionnelle à $\sigma/\sqrt{n}$

L'erreur standard est donc l'écart type de la distribution des moyennes d'échantillons possibles. *(question d'examen typique …)*

Concrètement, l'erreur standard mesure la précision avec laquelle on estime la moyenne. Les échantillons plus gros et peu dispersés sont plus précis car dans ce cas $\hat{\sigma}/\sqrt{n}$ devient plus petit.

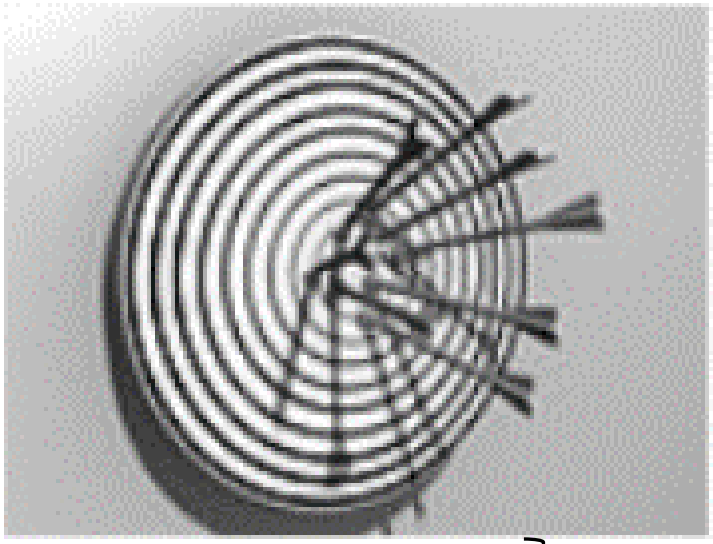

Gros échantillons
Échantillons peu variables
} plus précis

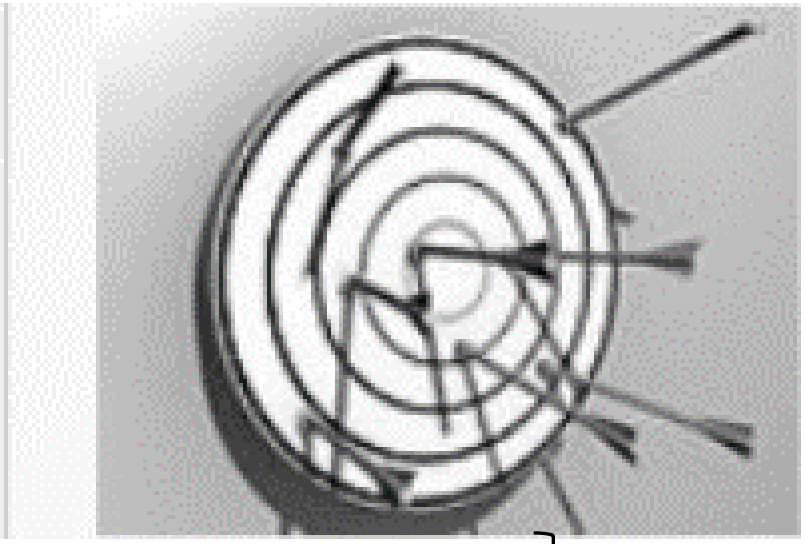

Petits échantillons
Échantillons très variables
} moins précis

Conséquence : dans $\hat{\sigma}/\sqrt{n}$, pour doubler la précision il faut quadrupler l'effectif : cela a un coût, souvent en temps de travail (de stagiaire de M1 par exemple …)

4) Intervalle de confiance

Notion d'intervalle de confiance :

On peut aller encore plus loin en exploitant le fait que la loi normale est une loi de probabilité.

Raisonnement de base des statistiques

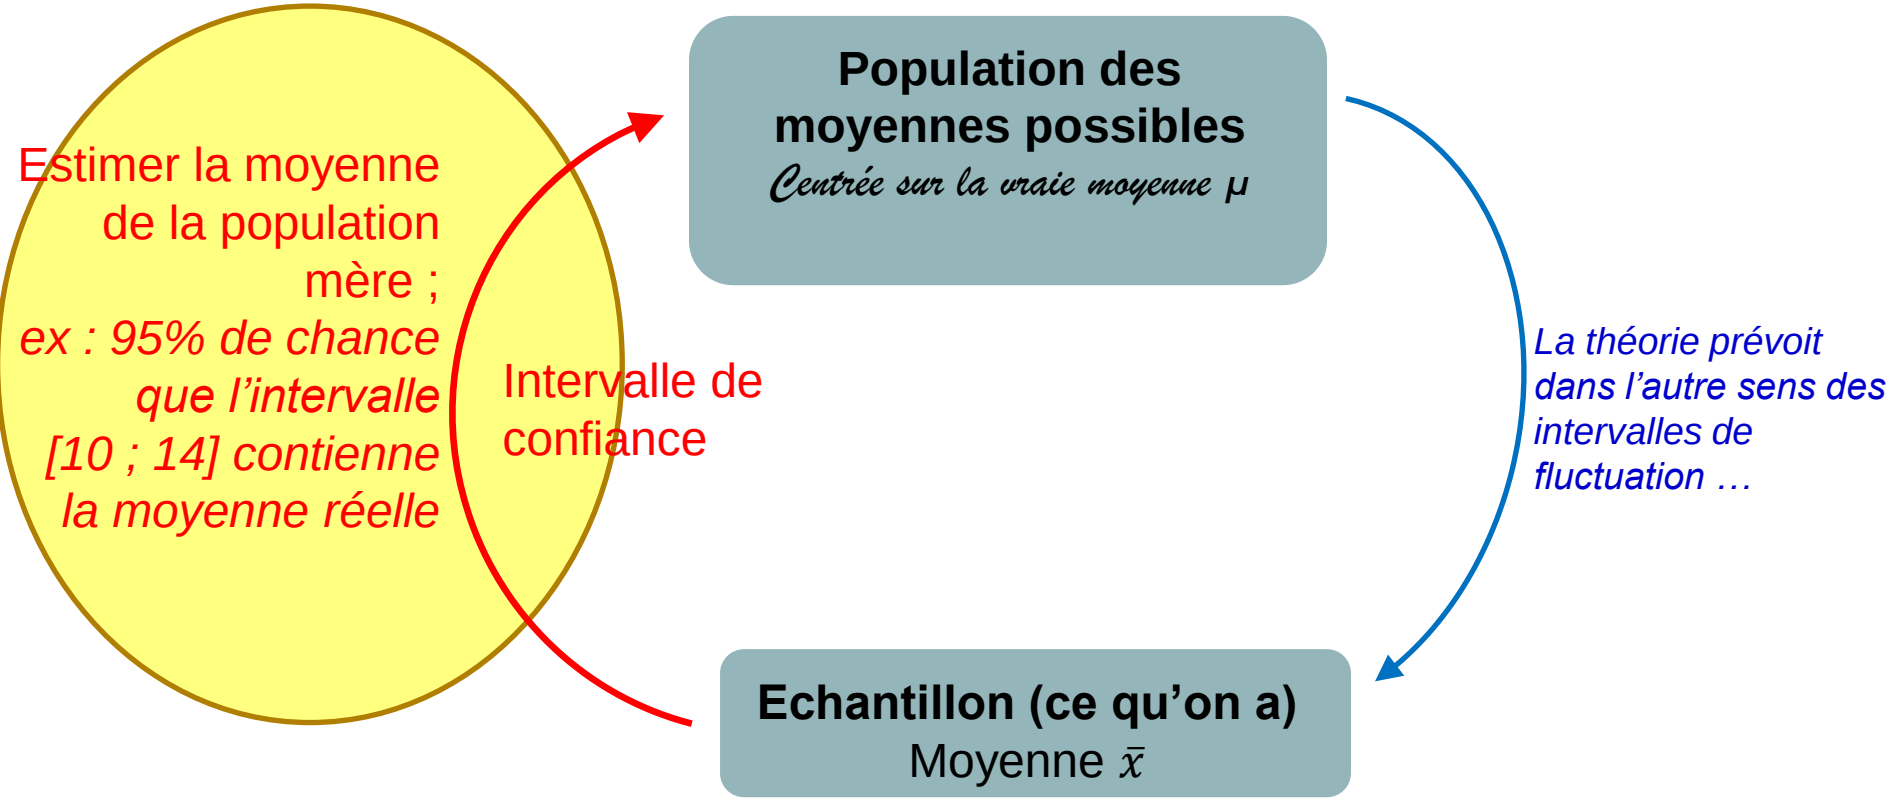

4) Intervalle de confiance

Comment bâtir cet intervalle de confiance ?

- Rappel : pour un échantillon infini (en pratique n ≥ 30), en vertu du théorème central limite les moyennes $\bar{x}$ qu'on observe dans les échantillons vont fluctuer selon une loi normale autour de la moyenne de la population, μ, avec un écart type qui est l'erreur standard $\sigma/\sqrt{n}$; et ceci quelle que soit la population

- Concrètement, l'amplitude des fluctuations est proportionnelle à l'erreur standard $\hat{\sigma}/\sqrt{n}$

4) Intervalle de confiance

- Méthode : on choisit une probabilité, puis on prend le complément à 1 que l'on nomme α. Par exemple : on veut un intervalle à 90%, α vaut donc 10%
- Si on veut un intervalle symétrique autour de $\bar{x}$ (cas le plus fréquent), on va donc prendre 45 % à gauche et 45% à droite de $\bar{x}$ c'est-à-dire répartir α de part et d'autre de $\bar{x}$ soit 5% de chaque côté ($^{\alpha}/_{2}$) pour avoir 90%.

LOI NORMALE

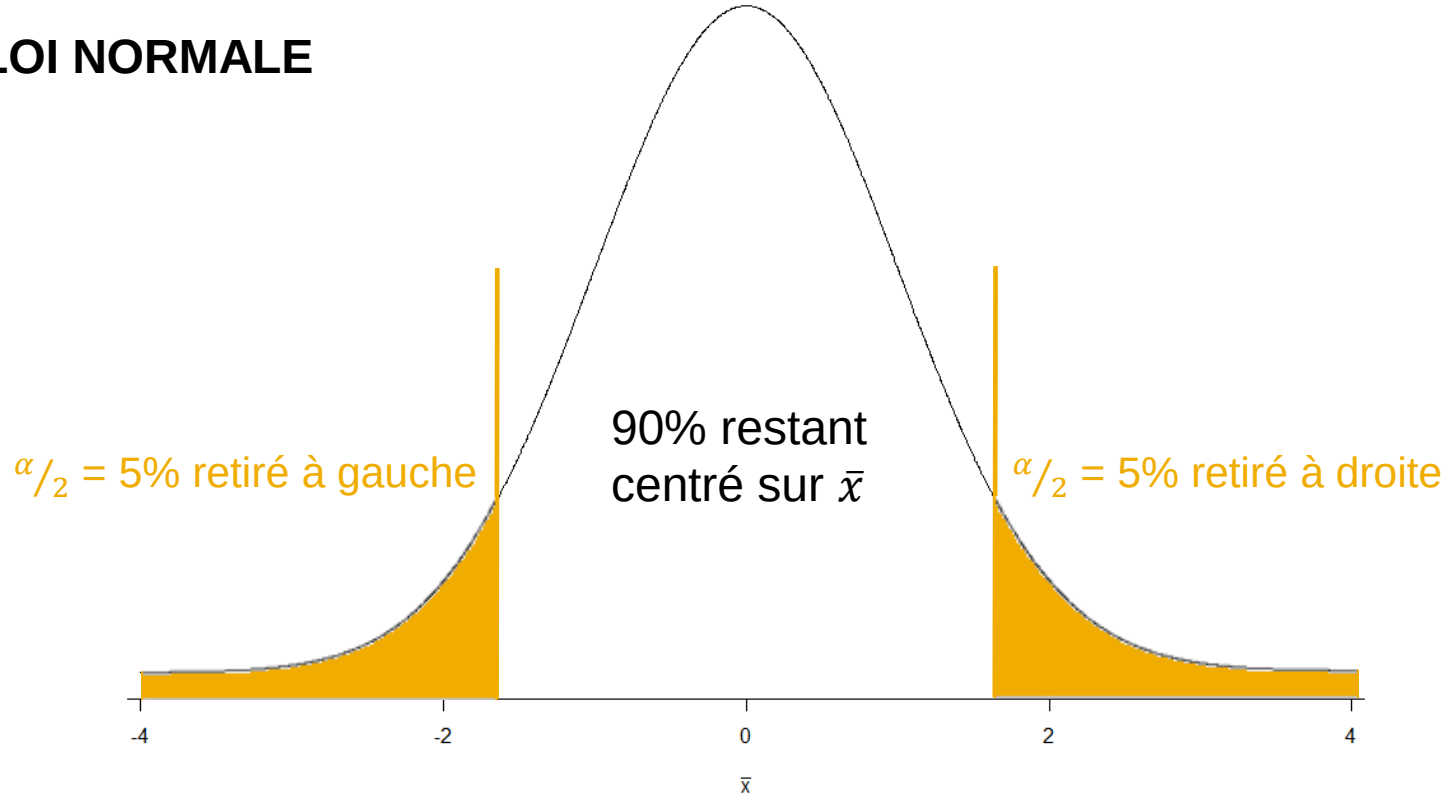

4) Intervalle de confiance

- Les valeurs de la loi normale correspondant à 5% et 95% sont -1,645 et 1,645 (on retrouve la symétrie).
- L'intervalle de confiance à 90% est compris entre $\bar{x}$ ± 1,645 erreur standard
- Cette valeur est appelée **quantile**

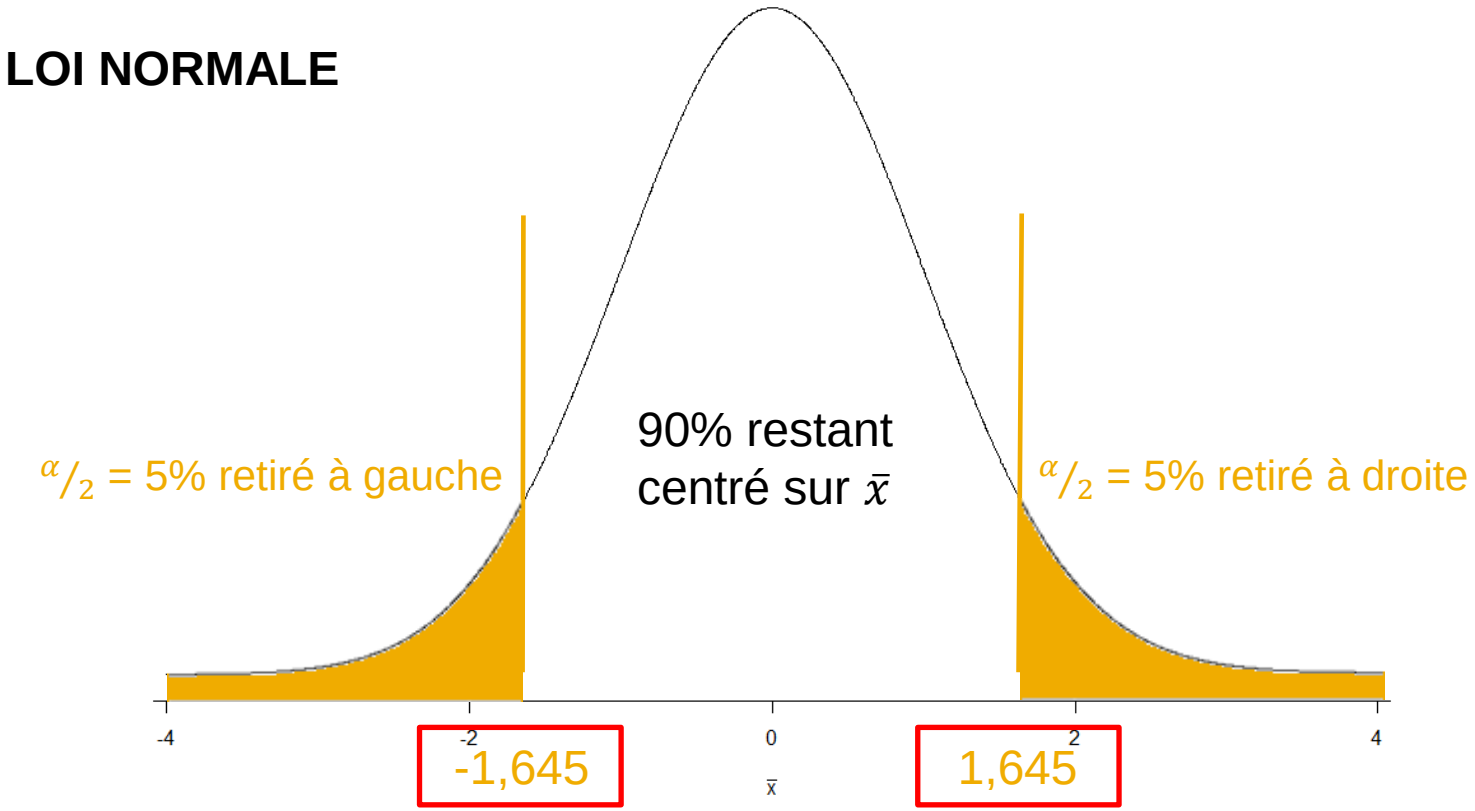

4) Intervalle de confiance

Formule générale :

$$\bar{x} \pm quantile_{\alpha/2} \, \hat{\boldsymbol{\sigma}} / \sqrt{n}$$

inclut μ (100-α)% du temps

- Mettre α à 0 pour avoir 100% de chance d'inclure μ donnera toujours un intervalle de ±∞, ce qui n'a aucun intérêt (et inclut effectivement μ 100% du temps)

- Pour les petits échantillons, le principe reste le même avec quelques complications (emploi de la loi de Student)

- Nous n'avons vu que des intervalles symétriques où α est réparti des deux côtés ; ils sont appelés dits bilatéraux (anglais : two-tailed). Il existe des intervalles unilatéraux (en anglais, one-tailed) où on ne met α que d'un seul côté, ils seront par exemple de la forme [-∞ ; 1,645] pour α = 5% (avec une erreur standard = 1 et $\bar{x}$ = 0).

- α est souvent appelé risque α, car il correspond au risque de ne pas inclure μ. On le fixe le plus souvent à 5%, plus ou moins arbitrairement.

V. DES INTERVALLES AUX TESTS

1) Une approche plus puissante que l'intervalle de confiance : le test

- La notion de test statistique est ce que vous devez à tout prix avoir compris.
- Les tests permettent de répondre à des questions expérimentales telles que « Ce traitement a t-il un effet ? » ou « Cet environnement est-il différent des autres ? » ...
- On bâtit les tests à partir d'intervalles de confiance.
- Tout comme pour les intervalles de confiance, on peut bâtir des tests unilatéraux, Ils sont rarement utilisés car il est difficile de les justifier.

1) Une approche plus puissante que l'intervalle de confiance : le test

- Exemple d'intervalle
  - Un échantillon de 40 valeurs a une moyenne $\bar{x}$ = 20, et un écart type $\hat{\sigma} = 3$, soit une erreur standard de 0,47.
  - L'intervalle 20 ± 1,96*0,47 a 95% de chance d'inclure μ
    (α = 5%, ± 1,96 est le quantile de la loi normale pour $^{\alpha}/_{2}$ = 2,5%)
  - En l'occurrence, cela donne [19,07 ; 20,93]

- Dans un test, les calculs sont semblables mais le raisonnement est différent
  - On pose une question comme : peut-on dire que μ = 20,5 ? μ = 22 ?
  - L'intervalle de confiance permet d'y répondre : ici, on peut dire que μ peut être égale à 20,5 (qui est inclus dans l'intervalle), mais pas à 22 (qui n'y est pas) avec cependant un risque α de 5%.
  - Les statistiques du 20ème siècle était enseignées de cette façon, mais il existe une approche plus moderne grâce aux ordinateurs : calculer une probabilité appelée p-value (le terme anglais est gardé pour lever toute ambiguïté)

2) Quel est le principe d'un test ?

- Repartons de la formule :

$$\bar{x} \pm quantile_{\alpha/2} \, \hat{\sigma}/\sqrt{n}$$

qui inclut μ avec un risque α de se tromper
(on a raison (100-α)% du temps)

- On part des questions : peut-on dire que μ = 20,5 ? μ = 22 ?
- Pour appliquer le test on va chercher à <u>calculer le quantile</u> qui vérifie :

$$\bar{x} \pm quantile_{\alpha/2} \, \hat{\sigma}/\sqrt{n} = \mu$$

c'est-à-dire :

$$\frac{\bar{x} - \mu}{\hat{\sigma}/\sqrt{n}} = quantile$$

- Naturellement, comme les quantiles sont symétriques on peut aussi poser μ - $\bar{x}$ au numérateur pour avoir une valeur positive. Le quantile obtenu est appelé <u>variable de décision</u> ou <u>statistique</u>.
- Au quantile est associée une probabilité $\alpha/2$: le α <u>correspondant est la p-value</u>
- Donc, le test revient à déterminer l'intervalle de confiance qui inclut μ avec un risque alpha égal à la p-value

2) Quel est le principe d'un test ?

- Retour à l'exemple : échantillon de 40 valeurs avec $\bar{x}$ = 20, et erreur standard de 0,47 ; on veut savoir si μ = 20,5 ? μ = 22 ? Avec la formule :

$$\frac{\bar{x} - \mu}{\hat{\sigma}/\sqrt{n}} = quantile$$

on obtient respectivement 1,054 et 4,216 comme quantile/variable de décision.

- R indique que les p-values correspondantes sont 0,292 et 0,000025.

Que faire de ces p-values ?

On les compare à un seuil α = 5%

- Si p ≥ 5%, on dit que le test n'est pas significatif.
  - Ici on accepte que l'échantillon provienne d'une population avec μ = 20,5. Si $\bar{x}$ = 20, c'est par hasard ; la probabilité d'avoir $|\bar{x} - \mu|$ ≥ |20-20,5| est de 29,2% dans ce cas, c'est donc loin d'être impossible.

- Si p < 5%, on dit que le test est significatif.
  - En l'occurrence, on doute fortement que l'échantillon provienne d'une population avec μ = 22, d'autant plus que p << 5% : si $\bar{x}$ = 20, ce n'est pas le hasard mais plutôt que la population mère a probablement μ ≠ 22. La probabilité d'obtenir par hasard $|\bar{x} - \mu|$ ≥ |20-22| est 0,0025% dans ce cas ; donc soit on a eu un résultat extraordinaire, soit -et c'est plus probable- μ ≠ 22.

2) Quel est le principe d'un test ?

- En résumé, **les tests servent à déterminer des p-values** par l'intermédiaire d'une statistique (ou variable de décision), qui est le quantile d'une loi statistique.
- **Cette p-value va ensuite servir d'outils d'aide à la décision.**
- Le but de ce module est en grande partie de vous apprendre à obtenir et utiliser à bon escient des p-values, notamment dans le cadre de vos travaux expérimentaux.

- La p-value mesure la fiabilité de notre décision (avantage par rapport à l'intervalle de confiance, qui est en « tout ou rien »). Malgré les apparences, elle ne mesure pas l'importance de l'effet. Donc, le terme « significatif » est un élément de jargon statistique qui signifie « pas dû au hasard » mais pas nécessairement « important ». C'est une source de confusion auprès des média par exemple ...

- Le test que l'on vient de faire est le test t de Student à un échantillon
  - Variante de nom pour le cas des grands échantillons : test z
  - En effet, le quantile de la loi normale est noté z …
  - … et celui de la loi de Student est noté t
  - De toute façon, pour les grands échantillons, on a $t \approx z$

2) Quel est le principe d'un test ?

Notion d'hypothèse

- La démarche que l'on vient de suivre est basée sur une hypothèse qu'il faut avoir à l'esprit quand on fait un test.
- En effet, le raisonnement mathématique sous-jacent aux tests part du principe que l'affirmation que l'on veut tester (dans nos exemples la valeur de μ) est exacte ; la valeur de la statistique et donc de la p-value en dépendent.
- On pose donc une « hypothèse nulle » notée H_0, et une hypothèse complémentaire dite hypothèse alternative notée H_1 ou H_a. Pour notre test t à un échantillon :
  - $H_0 : \mu = 22$
  - $H_1 : \mu \neq 22$

- Le calcul est fait en partant du principe que H_0 est vérifiée -on dit « sous H_0 ». Si la p-value est faible, cela veut dire soit qu'on a eu par hasard un évènement rare (voir très rare), soit qu'en réalité H_0 était fausse : on choisit donc de la rejeter au profit de H_1, mais ce n'est qu'un choix et pas une démonstration !!! Ce n'est qu'un outil d'aide à la décision.
- Les hypothèses dépendent du test fait, et sont modifiées en cas de test unilatéral.

- A titre indicatif, il existe une approche alternative des tests qui ne se base pas sur H_0/H_1 et les p-values : il s'agit des statistiques bayésiennes.

2) Quel est le principe d'un test ?

Définition de la p-value

- **La p-value est la probabilité, <u>si H_0 est vraie</u>, qu'une variable de décision soit égale ou plus extrême que la valeur calculée à partir des données.** (*Encore une question d'examen typique …*).

- Exemple : probabilité de trouver t ≥ |t calculé|
- Ce n'est donc pas du tout la probabilité que H_0 soit vraie !!! Simplement, si la p-value est trop basse, on **<u>choisit</u>** de conclure que les prémisses de notre raisonnement (c'est-à-dire l'hypothèse nulle H_0) sont fausses, et donc on la rejette.

Conditions d'utilisation

- Tout comme les intervalles, les tests ont des conditions d'utilisation. En l'occurrence, on n'utilise la loi normale que si les effectifs sont grands ; sinon (petits effectifs) il faut soit utiliser la loi de Student (si on pense que la population est gaussienne) soit utiliser les méthodes de permutation.
- De façon générale, les tests ont souvent des conditions d'utilisation à respecter. Ces conditions peuvent souvent être vérifiée à l'aide d'autres tests.
- Attention, si les conditions ne sont pas réalisées on peut quand même faire le calcul avec R, mais celui-ci ne signifiera plus rien !!!

3) Quel est la démarche que l'on suit toujours ?

Cette démarche n'est pas toujours explicite dans les articles ou les rapports, mais on la suit toujours. Il faudra la faire apparaitre dans le projet que vous rendrez, et on peut vous interroger dessus à l'examen.

1) Identifier les variables et identifier le problème, notamment en trouvant la nature des mesures et des facteurs (quantitative, nominale …).
2) Choisir le test (variable de décision) en fonction du 1) et poser $\alpha = 5\%$. La suite du cours expliquera quel test choisir dans chaque cas.
3) Vérifier si les conditions d'application du test sont remplies.
4) Poser H_0 et H_1.
5) Calcul de la statistique (la variable de décision) et obtention de la p-value. R fera ça pour vous.
6) Conclure en acceptant/rejetant H_0 puis en revenant à la question initiale.

4) La puissance des tests

- Relation entre la vérité et les décision prises en statistiques :

		Vérité (inconnue !) sur la population	
		H_0	H_1
Décision (selon l'échantillon et le test)	H_0	Correct ($p = 1 - \alpha$)	*Erreur !* ($p = \beta$)
	H_1	*Erreur !* ($p = \alpha$)	Correct ($p = 1 - \beta$)

- Si H_0 est vrai (ce qu'on ne sait pas), 2 cas dont une erreur
  - La probabilité *a priori* de cette erreur est α, fixé à 5%
- Si H_1 est vrai (ce qu'on ne sait pas), 2 cas dont une erreur
  - La probabilité *a priori* de cette erreur est β
  - La grandeur 1 – β est appelée **puissance du test**, concept important !!!
  - La puissance vaut dans l'idéal au moins 80% ; on ne peut l'estimer *qu'a priori*
- Les risques α et β sont liés : quand l'un augmente, l'autre diminue …

4) La puissance des tests

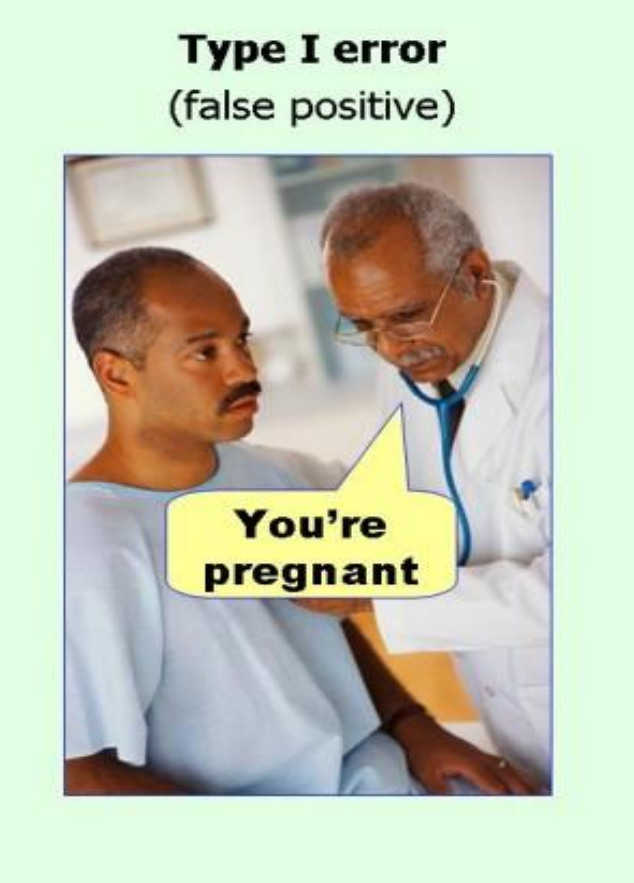

Erreur de type I:

- Risque que les données conduisent à rejeter H_0 alors qu'H_0 est vrai
- C'est le risque de première espèce α (que l'on compare à la p-value)

4) La puissance des tests

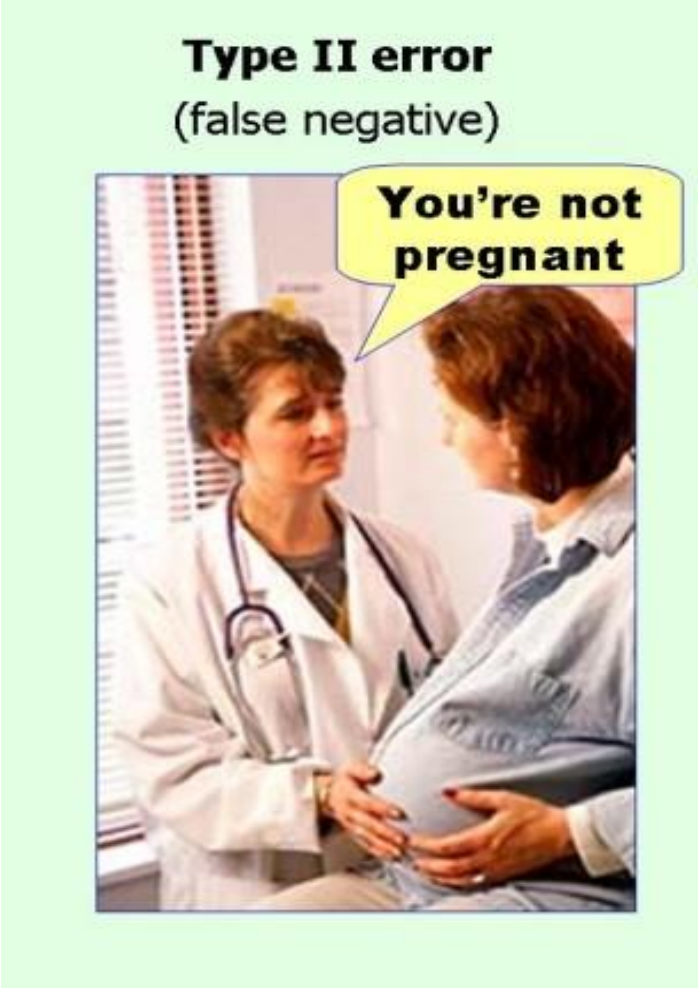

Erreur de type II

-Risque que les données nous conduisent à ne pas rejeter H_0 alors que H_0 est fausse.

- C'est le risque de deuxième espèce β
- Les risques α et β sont liés : quand l'un augmente, l'autre diminue …

4) La puissance des tests

- On retrouve le tableau précédent :

	Test result: Pregnant	Test result: Not Pregnant
Reality: Not Pregnant	Type I error (probability = α) *False Positive*	Probability = $1-\alpha$ *Correct Negative*
Reality: Pregnant	Power ($1-\beta$) *Correct Positive*	Type II error (probability = β) *False Negative*

4) La puissance des tests

Comment déterminer la puissance ?

- β est la probabilité *a priori* d'avoir à tort un test non significatif
- β dépend :
  - **de la taille de l'effet** (qui dépend elle-même de la variance)
  - de α
  - de l'effectif

- On ne peut pas déterminer la véritable taille de l'effet au vue des données, ce qui est contre-intuitif. Dans un test de Student, $\overline{x_1}$ estime μ_1, $\overline{x_2}$ estime μ_2, mais $\overline{x_1}$ - $\overline{x_2}$ **n'estime pas** $\mu_1 - \mu_2$!!!
  - Exemple : un test peut montrer facilement que les hommes sont plus grands que les femmes, mais ça ne nous dit pas de combien en moyenne
  - 0,1 à 0,2 est un effet de petite taille, et 0,5 à 0,8 est un gros effet ; mais ces conventions sont loin d'être établies et varient selon les tests

- Intérêt de la puissance (1- β) : déterminer les effectifs à employer
  - Effectifs *a priori* nécessaires pour détecter un effet d'une amplitude donnée
  - Assez pessimiste, voire irréaliste … Les tests ne sont pas très sensibles
  - Expérimentation animale : permet de justifier le nombre minimal d'animaux
  - Calcul par le logiciel G Power

http://www.psycho.uni-duesseldorf.de/abteilungen/aap/gpower3/

4) La puissance des tests

Exemple avec G-power : relation entre taille d'effet *d* et puissance d'un test t à un échantillon, selon la taille de l'échantillon

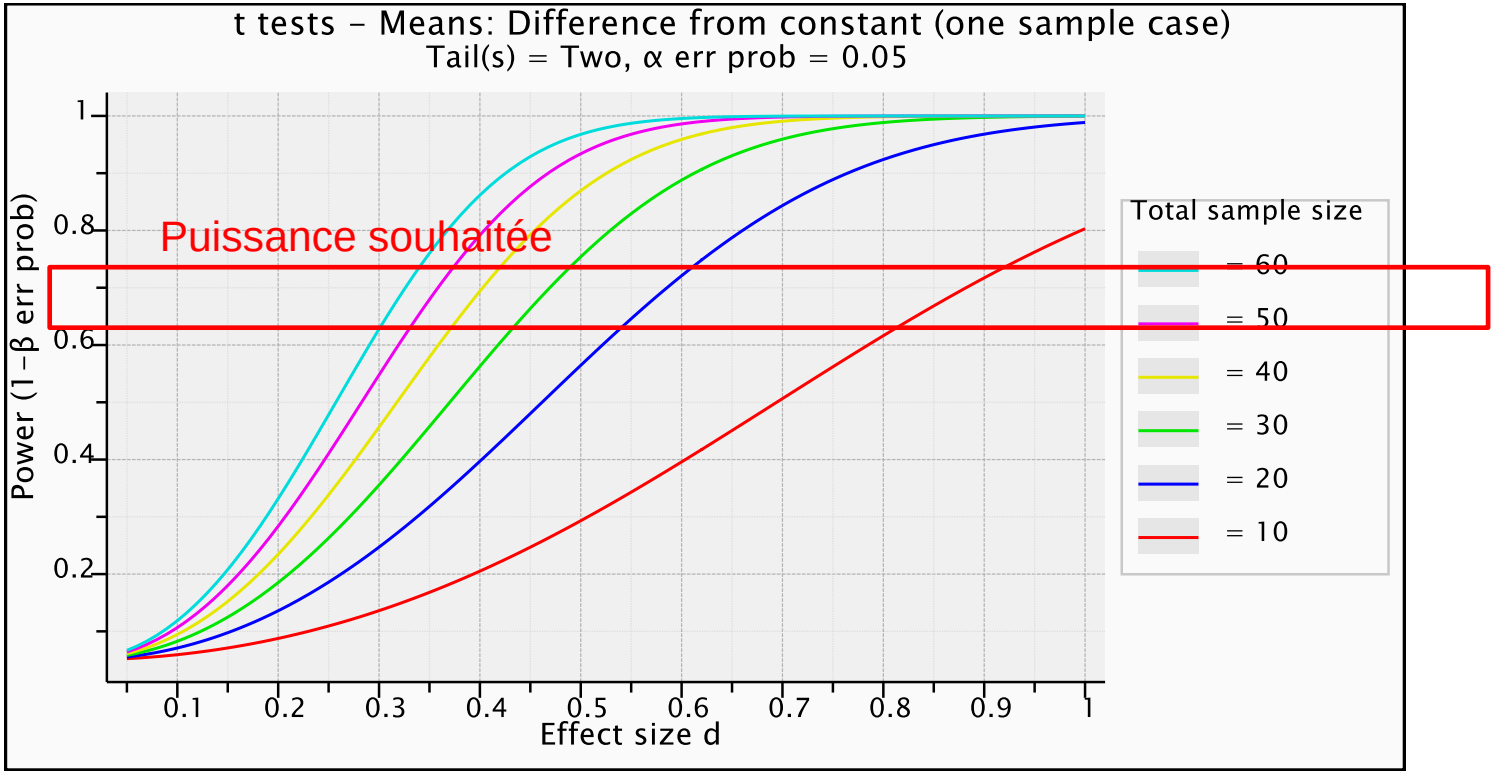

4) La puissance des tests

Quelques réflexions sur la puissance

- Retenez que souvent, la puissance est trop faible
- On peut donc manquer un effet qui existe (faux négatif)

Essay

Why Most Published Research Findings Are False

John P. A. Ioannidis

PLoS Medicine | www.plosmedicine.org 0696 August 2005 | Volume 2 | Issue 8 | e124

  - Soit les recherches ne détectent pas certains effets (β)
  - Soit elles détectent des effets imaginaires (α)
  - Soit elles surestiment l'amplitude des effets détectés

- Il faut **RÉPLIQUER** les données
- Quand il y a plusieurs groupes, essayer d'avoir des effectifs égaux (ou à peu près)

VI. PRÉSENTATION DES TESTS USUELS

voir poly table des tests

1) Les tests de Student

Test de Student à 1 échantillon

- On a un seul échantillon et on compare sa moyenne à une moyenne théorique
  - Obtenu avec l'intervalle de confiance de la moyenne
  - Degrés de liberté = n – 1

- Conditions
  - OK si $n \geq 30$
  - Sinon, il faut que la population mère soit gaussienne

- Hypothèses
  - H_0 : μ = moyenne théorique
  - H_1 : $\mu \neq$ moyenne théorique

1) Les tests de Student

Test de Student à 1 échantillon

- Commande R : t.test

```
> t.test(x,mu=10.5)

One Sample t-test
data:  x
t = -2.448, df = 24, p-value = 0.02206
alternative hypothesis: true mean is not equal to 10.5
95 percent confidence interval:
  9.195431 10.388944
sample estimates:
mean of x
  9.792187
```

Le nom des données

La moyenne théorique

La statistique, les degrés de liberté, la p-value ; conclusion ???

L'intervalle de confiance (inclut-il la moyenne théorique ?)

Hypothèse H_1 (redonnée quel que soit le résultat)

Moyenne de l'échantillon ($\bar{x}$)

1) Les tests de Student

Test de Student pour 2 échantillons indépendants

- On a deux échantillons A et B et on compare leurs moyennes μ_A et μ_B
  - Obtenu avec l'intervalle de confiance de la différence des moyennes μ_A et μ_B
  - Calcul de l'erreur standard de cette différence, qui change selon que les variances sont égales ou pas
  - Degrés de liberté = $(n_A - 1) + (n_B - 1) = n_A + n_B - 2$

- Conditions
  - Indépendance des deux groupes (pas de relations entre les individus), sinon il faut faire un test apparié
  - OK si $n_A \geq 30$ et $n_B \geq 30$
  - Sinon, il faut que les populations mères soient au moins à peu près normales
  - Deux versions du test : pour variances égales et pour variances différentes. Ce dernier modifie le calcul de l'erreur standard de la différence et les degrés de liberté (qui peuvent ne plus être entiers)

- Hypothèses
  - H_0 : $\mu_A - \mu_B = 0$ (les moyennes sont égales)
  - H_1 : $\mu_A - \mu_B \neq 0$ (les moyennes sont différentes)
  - On peut prendre un autre valeur que 0 (rare)

1) Les tests de Student

Test de Student pour 2 échantillons indépendants

- Commande R : t.test, 2 notations possibles

```
> t.test(a,b,var.equal=T)

> t.test(mesure~groupe,var.equal=T)

        Two Sample t-test

data:  mesure by groupe
t = -1.5557, df = 69, p-value = 0.1244
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -3.0408818  0.3762177
sample estimates:
mean in group a mean in group b
       9.949769       11.282101
```

Le nom des deux groupes à comparer

Les mesures, les groupes (a ou b dans l'exemple) ;
Cette notation de R avec un ~ s'appelle une formule

Les variances sont considérées égales
(mettre F au lieu de T dans le cas contraire)

La statistique, les degrés de liberté,
la p-value : conclusion ???

L'intervalle de confiance de la différence :
inclut-il 0 ?

Hypothèse H_1

Moyenne des échantillons ($\overline{x_A}$ *et* $\overline{x_B}$)

1) Les tests de Student

Test de Student pour 2 échantillons appariés

- On a deux échantillons A et B et on compare leurs moyennes μ_A et μ_B. Les mêmes individus ont été mesurés une fois en A, une fois en B.
  - On calcule un delta en faisant A - B pour chaque paire
  - On applique ensuite le test t pour un échantillon à ce delta, en prenant $\mu = 0$
  - Obtenu avec l'intervalle de confiance de la moyenne de delta
  - Sachant que $n_A = n_B = n_{delta} = n$, degrés de liberté = n – 1

- Conditions
  - Les deux groupes doivent être appariés (mêmes individus), sinon : test pour t pour échantillons indépendants
  - OK si $n \geq 30$
  - Sinon, il faut que le delta soit au moins à peu près normal (les distributions de A et B ainsi que leurs variances sont sans importance)

- Hypothèses
  - H_0 : $\mu_{delta} = 0$ (il n'y a pas de variation entre les deux groupes)
  - H_1 : $\mu_{delta} \neq 0$ (il y a une variation entre les deux groupes)
  - On peut prendre un autre valeur que 0 (rare)

1) Les tests de Student

Test de Student pour 2 échantillons appariés

- Commande R : t.test

```
> t.test(a,b,paired=T)

        Paired t-test

data: a and b
t = 0.96197, df = 25, p-value = 0.3453
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval: -0.9935636 2.7351893
sample estimates:
mean of the differences
0.8708128
```

Le nom des deux groupes à comparer

Indique que c'est un test apparié

La statistique, les degrés de liberté, la p-value ; conclusion ???

Hypothèse H_1

L'intervalle de confiance de delta : inclut-il 0 ?

Moyenne de delta

1) Les tests de Student

- Pour comparer plusieurs moyennes, on fait appel à une technique appelée ANOVA. On ne fait pas plusieurs tests de Student.

- S'il y a plusieurs facteurs et/ou que tout ou partie des facteurs sont continus, on emploie un modèle linéaire général (deuxième partie du module) et leur version appariée (modèles mixtes).

2) Tester l'égalité des variances

Test de Bartlett

- Ce test compare les variances d'un nombre quelconque de groupes.
  - Degrés de libertés = nombre de groupe -1 (donc pour deux groupes, 1 ddl)
  - Il existe une variante limitée à la comparaison de deux variances, le test de Fisher-Snedecor (aussi utilisé pour les ANOVA), et une autre qui ne suppose pas la normalité (test de Levene).
  - Lorsque les variances sont égales, on parle d'homoscédasticité, sinon d'hétéroscédasticité. En fait, le critère exact est que les moyennes et les variances ne soient pas proportionnelles, ce qui revient à des variances égales sous H_0.

- Conditions
  - Il faut que les populations mères soient normales. Ce test n'est pas très robuste (le test de Fisher-Snedecor non plus). Utiliser le test de Levene si nécessaire.

- Hypothèses
  - H_0 : $\sigma_A^2 = \sigma_B^2 = \ldots = \sigma_k^2$ (les variances sont égales)
  - H_1 : au moins une des variances est différente

2) Tester l'égalité des variances

- Commande R : bartlett.test

```
> bartlett.test(mesure~groupes)

Bartlett test of homogeneity of variances

data: mesure and groupe
Bartlett's K-squared = 0.046816, df = 1, p-value = 0.8287
```

Les mesures, les groupes (notation en formule)

La statistique, la p-value ; conclusion ???

3) Tester la normalité

- Il existe deux tests pour vérifier la normalité d'un échantillon : le test de Shapiro-Wilk et le test de Kolmogorov-Smirnov-Lilliefors.
  - Le test de Kolmogorov-Smirnov (sans la modification de Lilliefors) peut en plus tester si les données proviennent d'autres distribution que la distribution normale.
  - Le test de Kolmogorov-Smirnov peut aussi être utilisé pour vérifier si deux échantillons viennent d'une même distribution.
  - Ces tests n'ont pas de degrés de liberté.
  - Une autre façon de tester la normalité est le qq-plot, qu'on verra par la suite.

- Conditions
  - Il n'y en a pas.

- Hypothèses
  - H_0 : la distribution d'où provient l'échantillon est gaussienne
  - H_1 : la distribution d'où provient l'échantillon n'est pas gaussienne

3) Tester la normalité

- Commande R : shapiro.test

```
> shapiro.test(a)

Shapiro-Wilk normality test

data: a
W = 0.97019, p-value = 0.6284
```

Le nom des données

La statistique, la p-value ; conclusion ???

3) Tester la normalité

« Au secours, mes données ne sont pas normales !!! »

- Si un petit échantillon (n < 30) n'est pas gaussien et qu'on veut faire un test de Student, il existe plusieurs solutions.
  - Si les données sont à peu près gaussiennes (c'est-à-dire suivent une courbe en cloche), le test sera probablement valide, surtout si l'effectif n'est pas trop petit. Cette faculté de tolérer des écarts minimes à la théorie est appelée la robustesse du test.
  - Sinon, il est tout à fait possible de faire le test après avoir transformé les données de tous les groupes par une fonction non-linéaire : log(x), racine(x), 1/x, x^2 … Attention aux contraintes de ces fonctions (par exemple, que des valeurs positives pour le log).
  - Exemple connu : si les mesures sont comprises entre 0 et 1 (pourcentages), alors il faut les transformer par l'arcsinus de la racine carrée asin(sqrt(x))
  - Si ça ne marche toujours pas, il faut faire un test par ré-échantillonnage, qui ne suppose pas la normalité mais est légèrement moins puissant.
  - Une solution très souvent utilisée mais obsolète (car dépassée par les tests de ré-échantillonnage) consiste à faire des tests sur les rangs. Ils sont bien moins puissants et ne testent pas la même chose.

4) Test sur des données ordinales

- Si les données ne sont pas quantitatives mais qu'elles peuvent être triées (données qualitatives ordinales) on utilise des tests dit « non paramétriques » qui utilisent le rang des données.
- Comme leur nom l'indique, ces tests ne fonctionnent pas en comparant des paramètres comme la moyenne ou la variance, mais en comparant les distributions. En particulier, ils comparent indirectement la médiane.
- Les tests non paramétriques n'ont pas de condition d'utilisation (sauf le choix entre indépendant ou apparié).
- Ces tests peuvent être utilisés sur des données quantitatives (puisqu'elles sont ordinales elles aussi) mais ils sont beaucoup moins puissants que les tests conçus pour ces données (exemple : le test de Student) et ne teste pas la même chose (distribution plutôt que moyenne).

4) Test sur des données ordinales

- Tests typiques :
  - Le test de Mann-Whitney compare deux groupes indépendants, on l'appelle aussi test de la somme des rangs de Wilcoxon. Commande R :
    `wilcox.test(mesure~groupe)`
  - Le test de Wilcoxon (ou test des rangs signés) compare deux groupes appariés. Commande R :
    `wilcox.test(x,y,paired=T)`
  - Le test de Kruskall-Wallis compare n'importe quel nombre de groupes indépendants ; le test de Jonckheere-Terpstra fait la même chose pour des groupes définis par un facteur lui-même ordinal (ex : groupes des faibles, des moyens, des forts). Commandes R :
    `kruskal.test(mesure~groupes)` et `JonckheereTerpstraTest(mesure~groupes)` ce dernier étant dans le package DescTools (et donc pas disponible par défaut dans R).
  - Le test de Friedman compare n'importe quel nombre de groupes appariés. Commandes R :
    `friedman.test(mesure~groupes)`
  - Il existe aussi des équivalent du coefficient de corrélation que nous verrons plus tard (τ de Kendall et ρ de Spearman).
    Ils sont inclus dans la commande `cor.test`

5) Test sur des données nominales : les khi2 (ou chi2, ou χ^2)

- Rappel : les données nominales sont des données qualitatives non ordonnables. On ne peut que compter les différents états et faire des proportions (exemple : pourcentage de groupes sanguins dans une population).
- Ne pas confondre une mesure nominale rapportée par un pourcentage dans un échantillon (ex : pourcentage de groupes sanguins) avec un pourcentage mesuré sur chaque individu (ex : pourcentage de lipides dans l'alimentation)

- Les données nominales suivent des lois binomiale (si elles sont binaires) ou multinomiale (extension du binomial).
- Pour de grands échantillons, on pourrait appliquer le théorème central limite pour bâtir des intervalles de confiances et des tests de Student sur des proportions.
- En pratique, c'est très rarement employé, on utilise plutôt des tests basés sur une loi appelée χ^2. Les tests correspondants sont tout de même des intervalles de confiance déguisés.
- Les khi2 se calculent sur les comptages, et jamais sur les pourcentages donnés à l'échelle de l'échantillon ou de la population.
- La loi de khi2 est une loi continue, qu'on emploie ici pour décrire des données discrètes.
  - De ce fait, les khi2 auront une condition d'utilisation liée à la taille des effectifs, c'est le *critère de Cochran*.

5) Test sur des données nominales : les khi2

Comparer à une distribution théorique : le Khi2 de conformité

- Ce test compare une répartition de données nominales à une répartition théorique.
  - Ex : il y a en France 43% de groupe sanguin O, 45% de A, 9% de B et 3% de AB. On a un échantillon de 170 personnes : 75 O, 76 A, 7 B et 12 AB, correspondent-elles à cette distribution ?
  - Degrés de liberté = nombre de catégorie – 1 (ici, 3)

- Conditions
  - On calcule des effectifs théoriques en appliquant les proportions théoriques à l'effectif total : 170*43%, 170*45%, 170*9% et 170*3%
  - Il faut que 80% de ces effectifs théoriques soient supérieurs à 5 : c'est le critère de Cochran (qui est empirique)
  - Si ce n'est pas respecté, on peut faire un test exact binomial (s'il n'y a que deux catégories) ou khi2 par ré-échantillonnage

- Hypothèses
  - H_0 : l'échantillon correspond à la distribution théorique
  - H_1 : l'échantillon ne correspond pas à la distribution théorique

5) Test sur des données nominales : les khi2

Comparer à une distribution théorique : le Khi2 de conformité

- Commande R : chisq.test

```
> mesure=c(75,76,7,12)
> theorie=c(.43,.45,.09,.03)
> chisq.test(mesure,p=theorie)

Chi-squared test for given probabilities

data:  mesure
X-squared = 13.891, df = 3, p-value = 0.003058

> chisq.test(mesure,p=theorie)$expected
73.1 76.5 15.3 5.1
```

Saisie des données

La statistique, les degrés de liberté, la p-value ; conclusion ???

Vérification des effectifs théoriques : le critère de Cochran est-il respecté ?

5) Test sur des données nominales : les khi2

Comparer des distributions entre elles : khi2 sur table de contingence

- Ce test compare des répartitions de données nominales (à deux valeurs ou plus) dans deux groupes ou plus
- Il y a des degrés de liberté calculé selon la formule (ligne - 1) * (colonne - 1) dans la **table de contingence**.

5) Test sur des données nominales : les khi2

Comparer des distributions entre elles : khi2 sur table de contingence

- Qu'est-ce qu'une table de contingence ?

		Groupes (niveau du facteur)				
		Groupe 1	Groupe 2	…	Groupe k	
Mesures	Mesure A	Nb. de mesures	Nb. de mesures	Nb. de mesures	Nb. de mesures	Somme de la ligne
	Mesure B	Nb. de mesures			Nb. de mesures	Somme de la ligne
	…	Nb. de mesures			Nb. de mesures	Somme de la ligne
	Mesure k	Nb. de mesures	Nb. de mesures	Nb. de mesures	Nb. de mesures	Somme de la ligne
		Somme de la colonne	Somme de la colonne	Somme de la colonne	Somme de la colonne	**TOTAL**

Ces sommes permettent de déterminer des effectifs théoriques pour calculer le khi2

Il y a L lignes

Il y a C colonnes

- Il y a (L-1)*(C-1) = *d* degrés de liberté
- Avec *d* valeurs dans la table on peut complètement la reconstituer étant donné que les sommes des lignes et des colonnes sont fixées (d'où le nom de contingence)

5) Test sur des données nominales : les khi2

Comparer des distributions entre elles : khi2 sur table de contingence

- Ce test compare des répartition de données nominales (à deux valeurs ou plus) dans deux groupes ou plus, qui doivent être **indépendants**
- Il y a des degrés de liberté calculé selon la formule (ligne - 1) * (colonne - 1) dans la **table de contingence**
- La table de contingence sert de base aux calculs de ce test : c'est à partir d'elle qu'on détermine des effectifs théoriques.

- Conditions
  - Des effectifs théoriques sont calculés à partir de la table de contingence
  - Il faut que 80% de ces effectifs théoriques soient supérieurs à 5 : c'est le critère de Cochran
  - Si ce n'est pas respecté, on peut faire le test exact de Fisher (qui n'a pas de conditions mais est légèrement moins puissant) avec la fonction `fisher.test` (qui ne fait donc pas le test de Fisher-Snedecor) ou un khi2 par ré-échantillonnage
  - Dans le passé on regroupait certains groupes, c'est à présent obsolète

- Hypothèses
  - H_0 : pas de lien entre lignes et colonnes (mesure et facteur en pratique)
  - H_1 : lien entre lignes et colonnes (mesure et facteur en pratique)

5) Test sur des données nominales : les khi2

Comparer des distributions entre elles : khi2 sur table de contingence

- Commande R : chisq.test

```
> chisq.test(table,correct=F)

Pearson's Chi-squared test

data:  table
X-squared = 12.348, df = 6, p-value = 0.05464

Warning message:
In chisq.test(table, correct = F) :
  l'approximation du Chi-2 est peut-être incorrecte

> chisq.test(table,correct=F)$expected
 [,1]     [,2]      [,3]      [,4]
[1,] 13.055556 8.703704 13.925926 11.314815
[2,] 10.277778 6.851852 10.962963  8.907407
[3,]  6.666667 4.444444  7.111111  5.777778


Warning message:
In chisq.test(table, correct = F) :
  l'approximation du Chi-2 est peut-être incorrecte
```

Il travaille directement sur une table. « Correct=F » doit être précisé (surtout pour les table 2*2).

La statistique, les degrés de liberté, la p-value ; conclusion ???

Vérification des effectifs théoriques : le critère de Cochran est-il respecté ?
NB : R affiche un warning si au moins une des valeurs théoriques est plus petite que 5

5) Test sur des données nominales : les khi2

Remarques complémentaires

- S'il y a plusieurs facteurs et/ou que tout ou partie des facteurs sont continus, on utilise un modèle linéaire généralisé : la régression logistique (seconde partie du module), à condition que la mesure soit binaire.
- Par construction, le khi2 est toujours unilatéral : comme son nom l'indique c'est un carré, et comme un carré est toujours positif on ne regarde pas la gauche de la distribution

- Cas des données appariées (non indépendantes)
  - Deux groupes, mesure binaire : test de McNemar (`mcnemar.test`)
  - N groupes, mesure binaire : test Q de Cochran (Fonction `CochranQTest` dans le package DescTools de R, non chargé par défaut)
  - S'il y a plusieurs facteurs et/ou que tout ou partie des facteurs sont continus, on emploie modèle linéaire généralisé mixte ou une procédure appelée Generalized Estimating Equation (GEE)

- Remarquez donc que dès qu'on introduit plusieurs facteurs et/ou des facteurs appariés, il faut avoir des mesures binaires …

- A la place du khi2, on peut employer un test appelé test G (ou test du rapport de vraisemblance), mais il est rarement utilisé. Il n'est ni meilleur ni pire que le khi2 mais le calcul n'a rien à voir.

5) Test sur des données nominales : les khi2

Cas des facteurs à plusieurs niveaux

- Si le facteur d'un khi2 significatif a plusieurs niveau, on ne sait pas qui diffère de qui
  - Ex : on compare la répartition homme femme en master psychologie, mathématique et SDUEE et il y a une différence
- Problème : <u>on ne peut pas simplement faire les comparaisons 2 à 2</u>
  - Le risque α n'est plus de 5% dans ce cas, il augmente avec le nombre de tests ! Ca revient à dire que les p-values sont trop basses (trop souvent significatives).
  - Comme pour le test t, des méthodes plus complexes existent face à ce problème (la régression logistique résout le problème)
  - On peut aussi ajuster les p-values

- L'ajustement des p-value
  - Ex : on fait les 3 tests psychologie/math, psychologie/SDUEE, math/SDUEE, et on obtient 3 p-value dont on sait qu'elles sont trop basse
  - On va donc les ajuster en les remplaçant par une p-value ajustée
  - Mauvaise façon de faire : la correction de Bonferroni multiplie toutes les p-values par le nombre de comparaisons nc (nc = 3 dans l'exemple)
  - Bonne façon : la correction de Holm (ou Bonferroni séquentiel) multiplie la p-value la plus basse par nc, puis la suivante par nc-1, etc … sans changer l'ordre
  - Il existe d'autres méthodes plus complexes

5) Test sur des données nominales : les khi2

Cas des facteurs à plusieurs niveaux

- Commande R : p.adjust

```
> p.adjust(c(0.008,0.009,0.020,0.045),method="holm")
0.032 0.032 0.040 0.045
```

La liste des p-values (peu importe l'ordre) et la méthode choisie (voir l'aide)

0.008 * 4 = 0,032
0,009 * 3 = 0,027, ramené de force à 0,032 pour garder l'ordre
0,020 * 2 = 0,040
0,045 * 1 = 0,045

FIN DE LA PREMIÈRE PARTIE

Illustration de la loi normale dans un intervalle de fluctuation

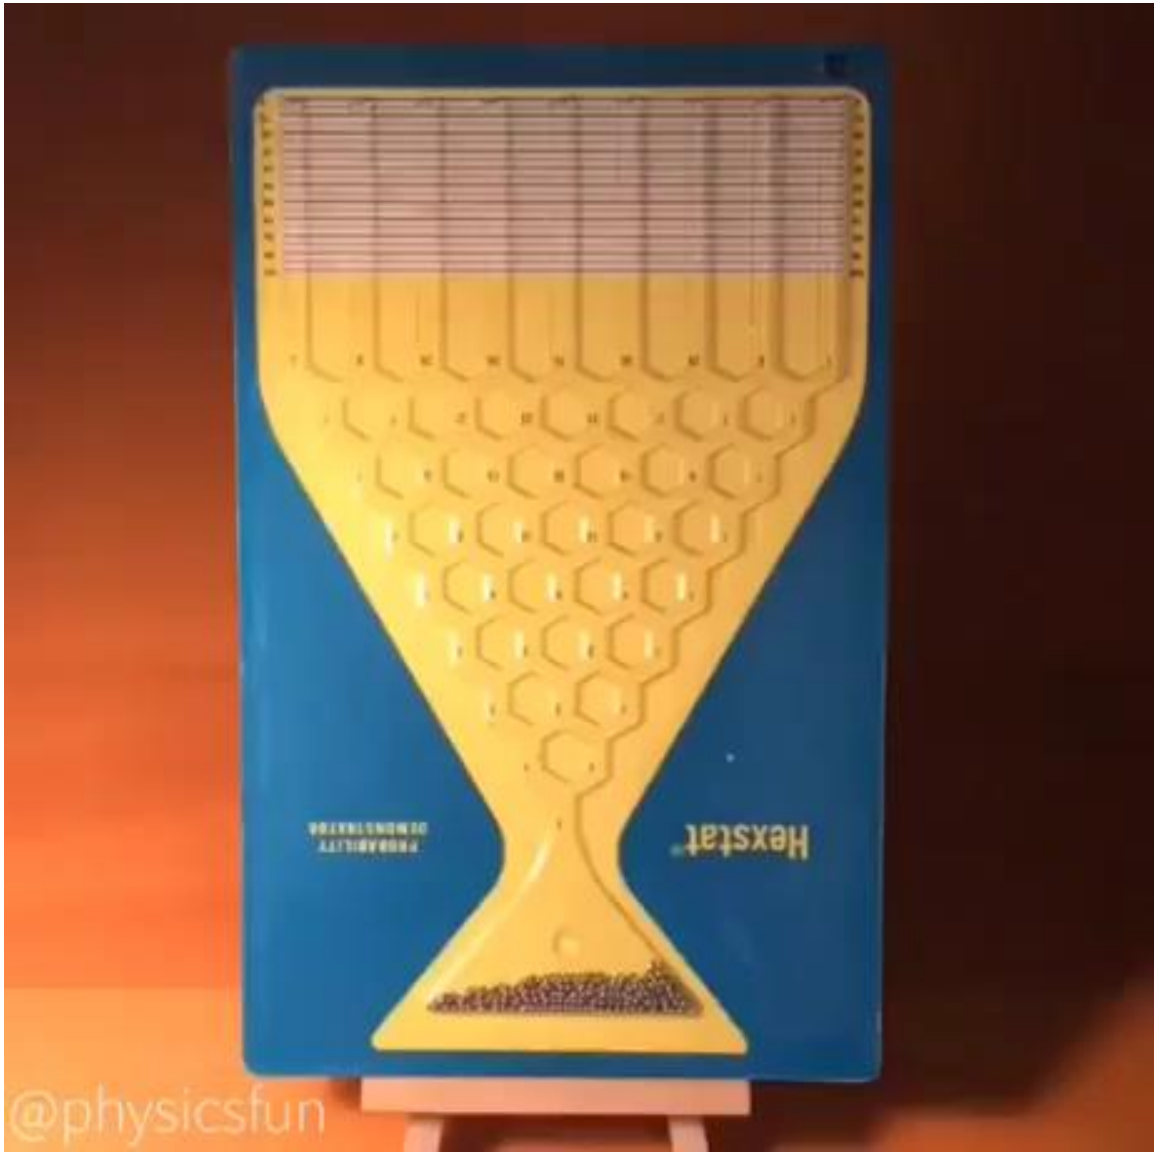

- Chaque bille représente la moyenne $\bar{x}$ d'un échantillon
- L'intervalle de fluctuation permet de délimiter la zone où tomberons *la plupart* des billes (ce « la plupart » est en fait une proportion définie).
- La taille de cette zone dépend de l'erreur standard $\sigma/\sqrt{n}$
- En raisonnant dans l'autre sens, on peut prévoir d'où venaient les billes, c'est **l'intervalle de confiance**

Usage des intervalles de confiance

Connaissant $\bar{x}$ et son erreur standard $\hat{\sigma}/\sqrt{n}$ on va pouvoir :

1. Soit :
   - poser des bornes …
   - … et grâce à la loi normale en déduire la probabilité que l'intervalle défini par ces bornes contienne μ.
   - Exemple : je choisis des bornes de 11 et 12
     → cet intervalle 17% de chance de contenir μ
2. Soit :
   - poser une probabilité p …
   - … et grâce à la loi normale en déduire les bornes d'un intervalle symétrique une probabilité p de contenir μ
   - Exemple : je choisis une probabilité de 95%
     → l'intervalle [9,5 ; 14,5] à 95% de chance de contenir μ

Pourquoi pas un intervalle à 100% ?

Parce qu'il irait de $-\infty$ à $+\infty$ … Comme c'est trivial ça ne sert à rien, on prend donc un petit risque (5%) de rater la moyenne et en échange on a un intervalle beaucoup plus étroit.

Usage des intervalles de confiance

- Exemple en posant des <u>bornes</u> pour en déduire des <u>probabilités</u> :
  - Probabilité que μ soit au dessus de $\bar{x}$ + $1 * \hat{\sigma}/\sqrt{n}$ = 15,87%
  - Probabilité que μ soit en dessous de $\bar{x}$ - $1 * \hat{\sigma}/\sqrt{n}$ = 15,87% (c'est symétrique)
  - Probabilité que μ soit dans un intervalle de $\bar{x}$ ± $1 * \hat{\sigma}/\sqrt{n}$ = 1-2*15,87% = 68,26%
  - Si erreur standard = 0,5 et $\bar{x}$ = 6, [5,5 ; 6,5] inclura μ à 68,26% de chance

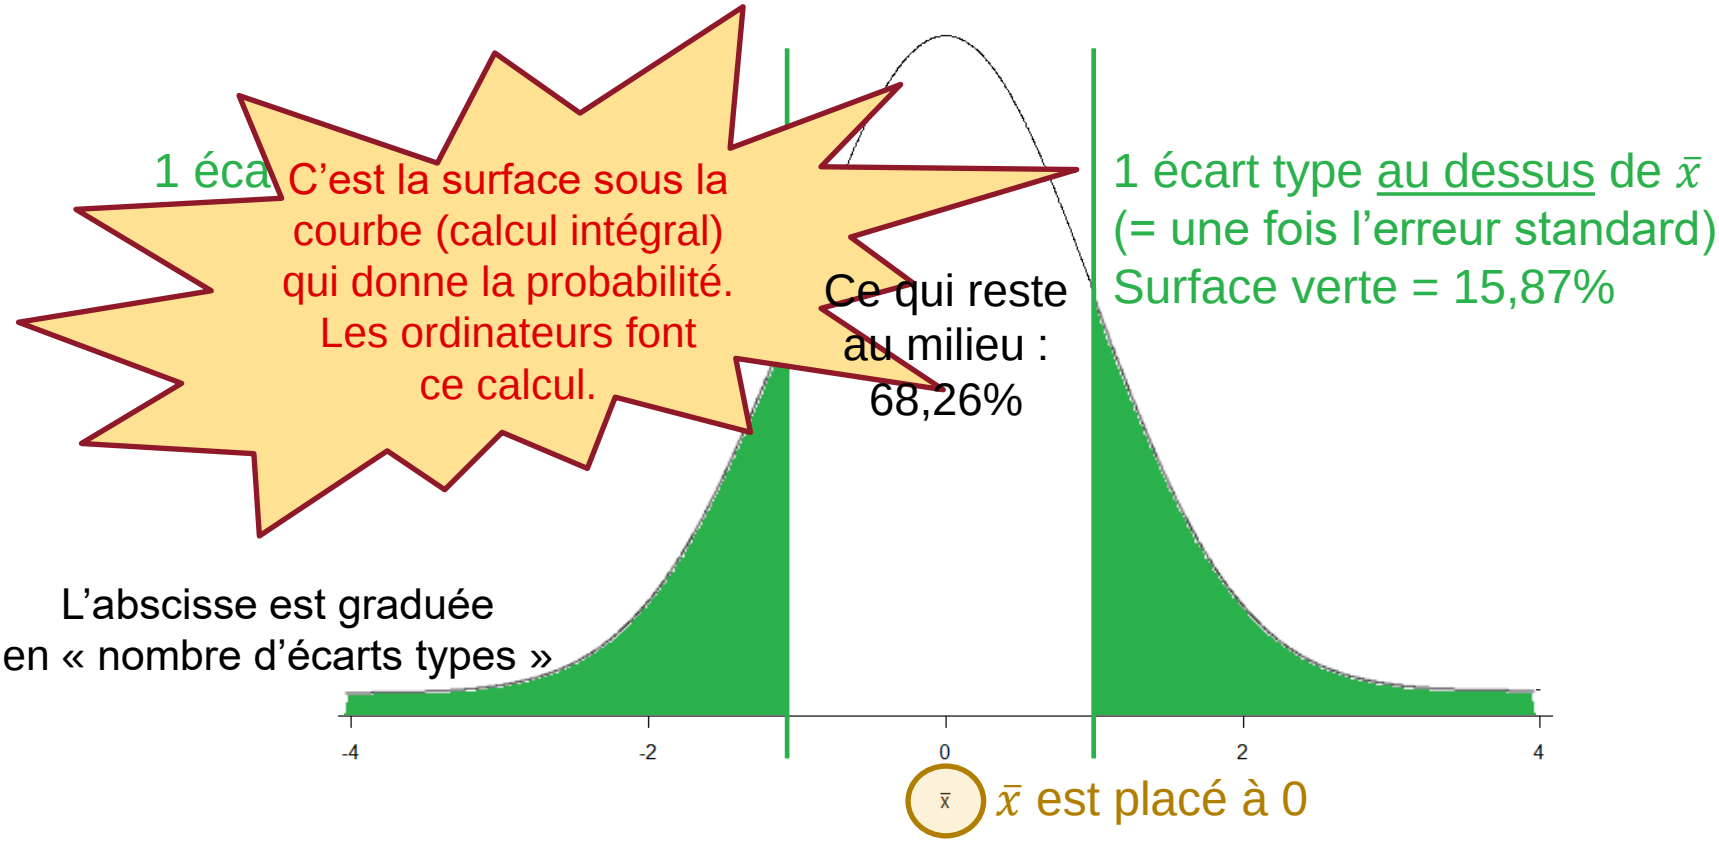

Intervalle de confiance avec la loi de Student

Convergence de la loi de Student (en bleu) vers la loi normale (en noir) :

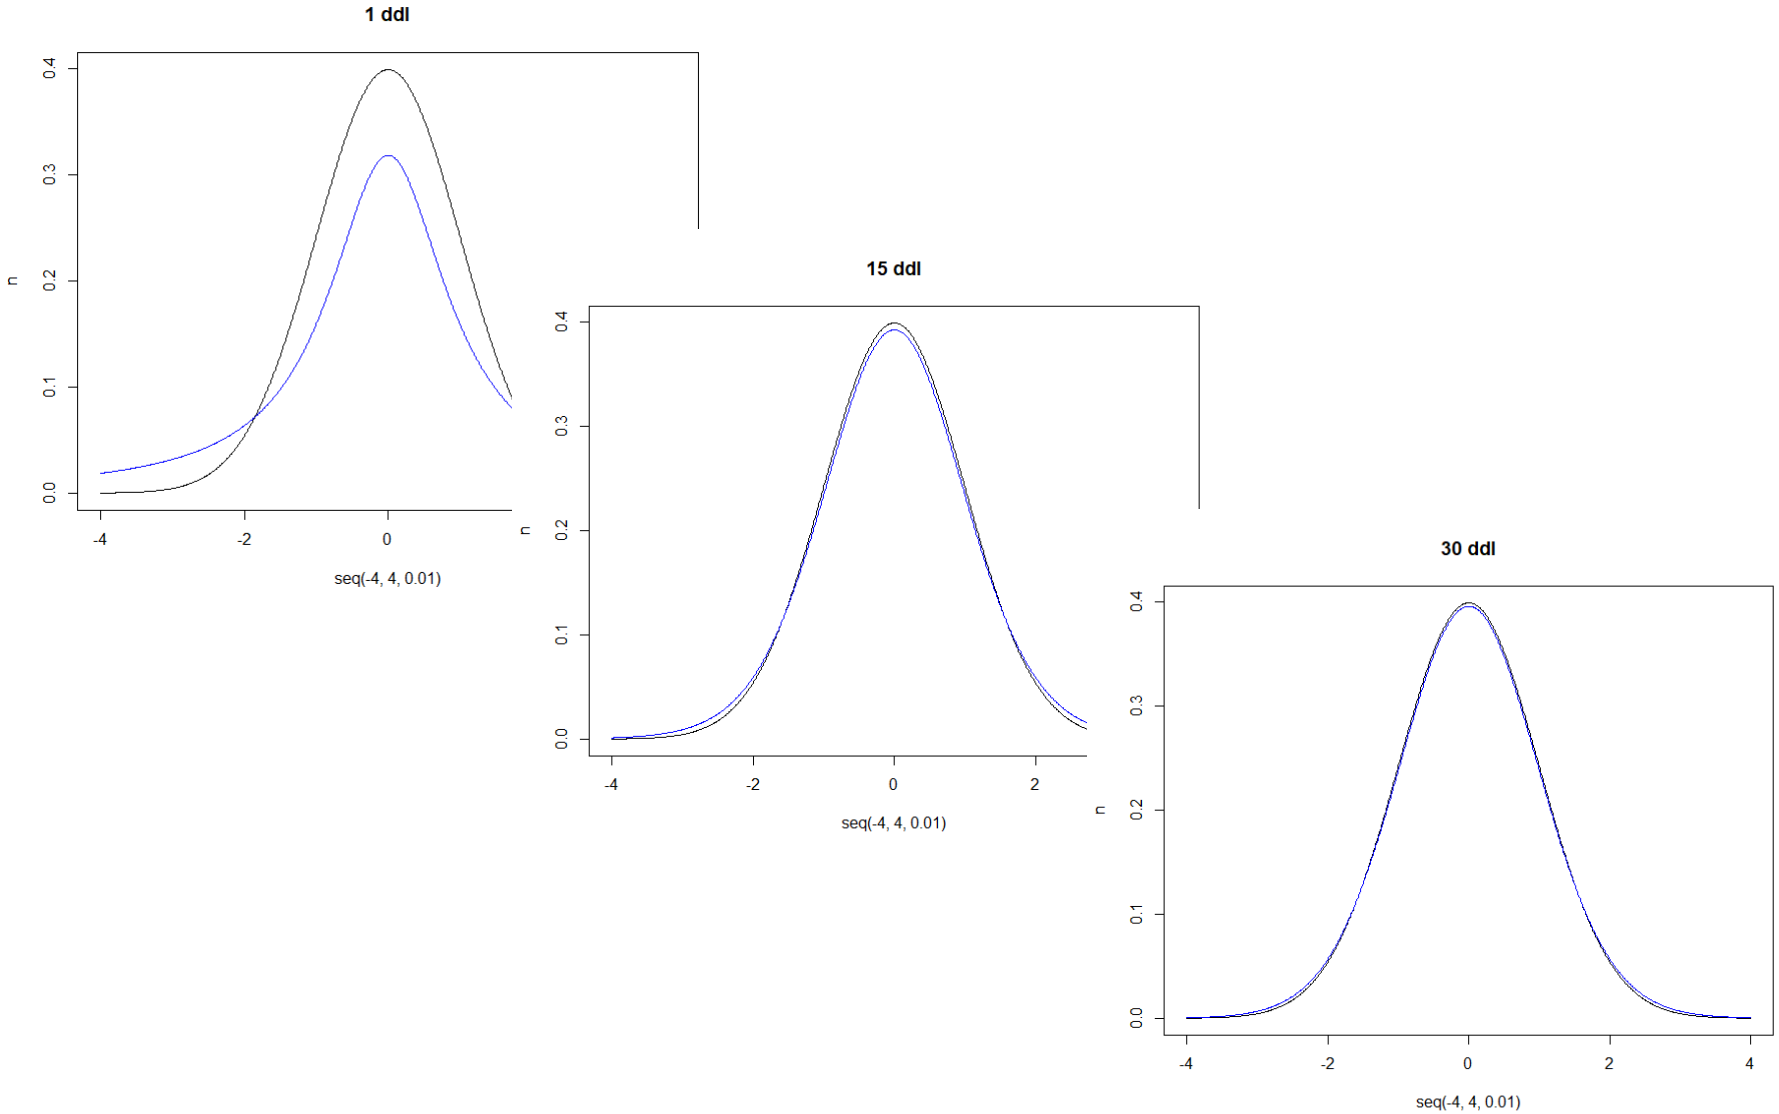

Démonstration de R

A ce stade, le but est d'illustrer ce qu'on vient de voir, pas de comprendre en détails …

```
# échantillon de 50 valeurs dans une population suivant une loi de Poisson de moyenne 10
> echant = rpois(50,10)
9 12 12  2  5 12 16 10 15 11 12 12 14  7  7 10 12  8  6 17  8  6 11  2  8 11 10 6  6 11  9  5 11
4  7  7  9  8 11 15 14  8  6 11  5 13 13  9 11 13

# moyenne de l'échantillon
> mean(echant) 9.54
# Ce n'est pas trop loin de 10

# erreur standard
> err.stand = sd(echant)/sqrt(50) 0.493

# Borne inférieure
> qnorm(0.025,9.54,err.stand,lower.tail=TRUE) 9.07

# Borne supérieure
> qnorm(0.025, 9.54,err.stand,lower.tail=FALSE) 11.01

# La vraie moyenne μ sera 95% du temps dans l'intervalle [9.07 ; 11.01] ; ici c'est bien le cas
# En pratique on ne se sert pas de ces étapes dans R, car il y a une façon bien plus simple et
directe d'obtenir l'intervalle : la fonction t.test
```

Grand échantillon, donc ça marche même avec une loi de Poisson

Référence à la loi normale

Référence à l'erreur standard et à la moyenne $\bar{x}$

Les 2,5% inférieurs et supérieurs correspondent à $\alpha/2$ (intervalle de confiance à 95%)

4) Intervalle de confiance

Remarques complémentaires

- On peut calculer l'intervalle de confiance de n'importe quel paramètre (moyenne, variance, médiane …) avec des échantillons de toute taille venant de n'importe quelle population avec une technique appelée ré-échantillonnage. Cela repose sur une simulation numérique appelée bootstrap (ou simulation Monte-Carlo) qui nécessite un ordinateur.
- Le ré-échantillonnage est très utile pour calculer un intervalle pour un petit échantillon non-gaussien, ou pour travailler sur autre chose que la moyenne.
- Pour les moyennes, les méthodes précédentes (loi normale pour les grand échantillons et loi de Student pour les petits échantillons gaussiens) donnent à peu près le même résultat tout en étant plus simple.

Intervalles et puissance des tests

Illustration de α

On obtient un échantillon d'une population de moyenne μ.

H_0 : μ est dans l'intervalle de confiance autour de $\bar{x}$ (les lignes verticales noires)
Le risque de première espèce correspond à la probabilité que la moyenne de la population μ soit située dans la zone de rejet d'aire α (les surfaces bleues). On conclut alors que l'échantillon ne vient pas de la population alors qu'en fait il en vient !

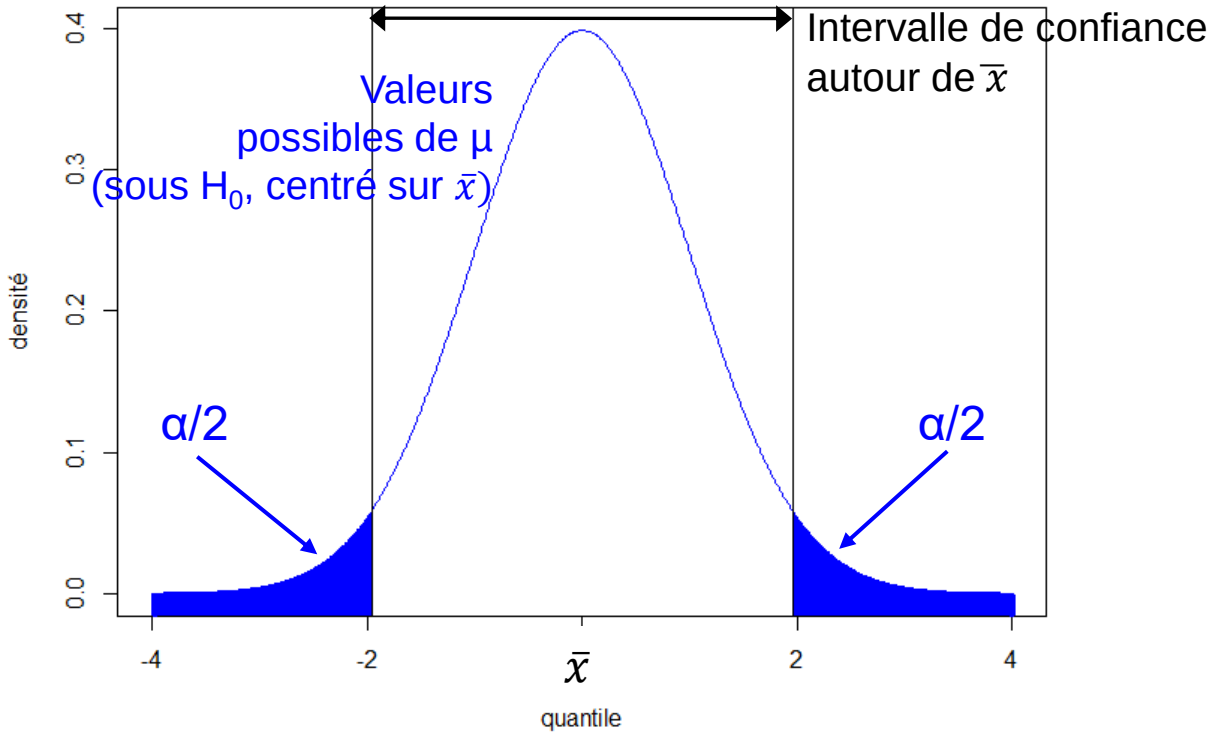

Intervalles et puissance des tests

Illustration de β

On obtient un échantillon d'une population de moyenne μ0. On considère une population de moyenne μ différente de μ0.

H_0 : μ est dans l'intervalle de confiance autour de $\bar{x}$ (les lignes noires).
Le risque de deuxième espèce β correspond à la probabilité que la moyenne de la population μ soit incluse dans l'intervalle de confiance tiré de l'échantillon (surface rouge). On conclut alors que l'échantillon vient de la population de moyenne μ alors que c'est faux !

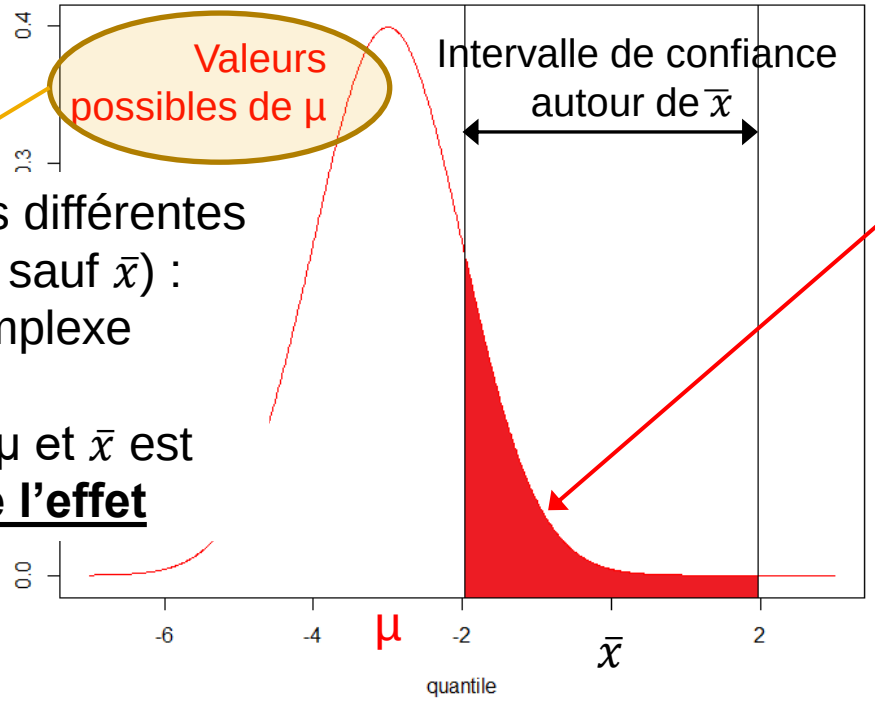

Nombreuses valeurs différentes de μ (en fait tout sauf $\bar{x}$) : calcul de β complexe

L'écart réel entre μ et $\bar{x}$ est appelé **taille de l'effet**

Cas particulier avec le khi2

Le paradoxe de Simpson

- Les khi2 (et en fait tous les tests vus jusqu'à présent) n'ont qu'une seule mesure et un seul facteur.
- L'existence de facteurs sous-jacents peut modifier drastiquement les conclusions.
- Exemple historique : on compare 2 traitements A et B pour guérir les calculs rénaux
  - A guéri 78% des calculs (273/350) et B guéri 83% (289/350)
  - Mais en réalité A est le plus efficace ! On le voit en prenant en compte le facteur « Taille du calcul »

	Traitement A	Traitement B
Petits calculs	93% (81/87)	87% (234/270)
Gros calculs	73% (192/263)	69% (55/80)

  - En réalité, A a surtout été testé sur les gros calculs, qui sont plus difficile à guérir. Il fait mieux que B dans tous les cas.
- C'est le paradoxe de Simpson

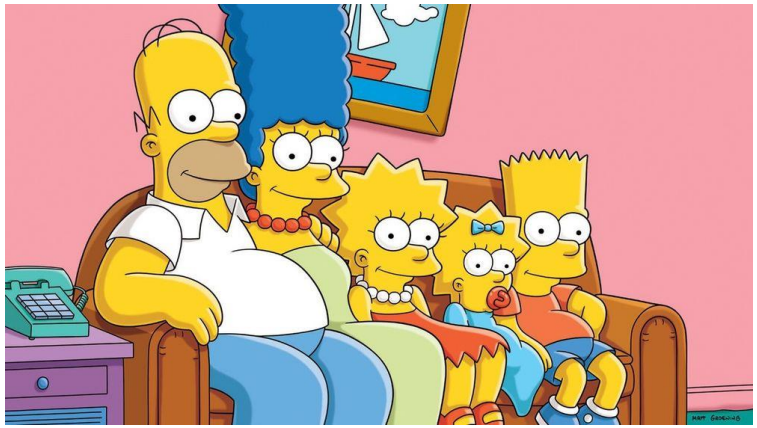

Cas particulier avec le khi2

Le paradoxe de Simpson

- Illustration :

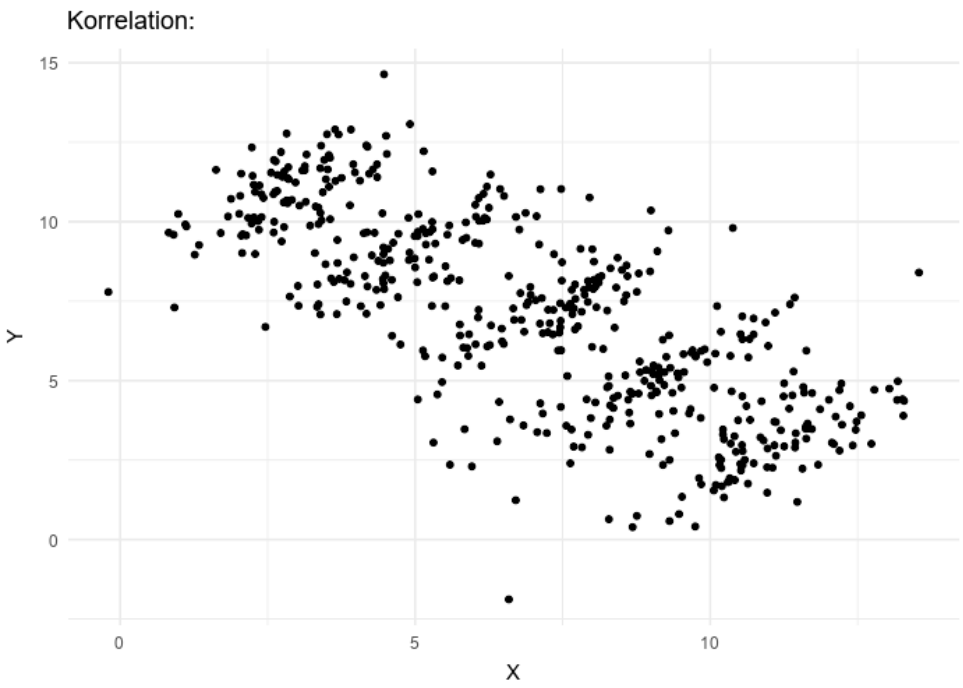

- Pour l ‘éviter : prendre en compte tous les facteurs avec les méthodes appropriées. De plus, jusqu’à présent on n’a considéré que des facteurs discrets et non continus.
- Ce risque existe aussi pour le test de Student, qui est en plus limité aux facteurs à 2 niveaux. Là encore, il faut employer d’autres méthodes si nécessaire.

- La suite du cours va justement présenter ces fameuses méthodes, auxquelles nous avions déjà fait allusion. Le programme pour le contrôle continu s’arrête ici.

Attention aux résumés numériques et graphiques

- Troisième exemple : le quartet d'Anscombe

Anscombe's Quartet
Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.

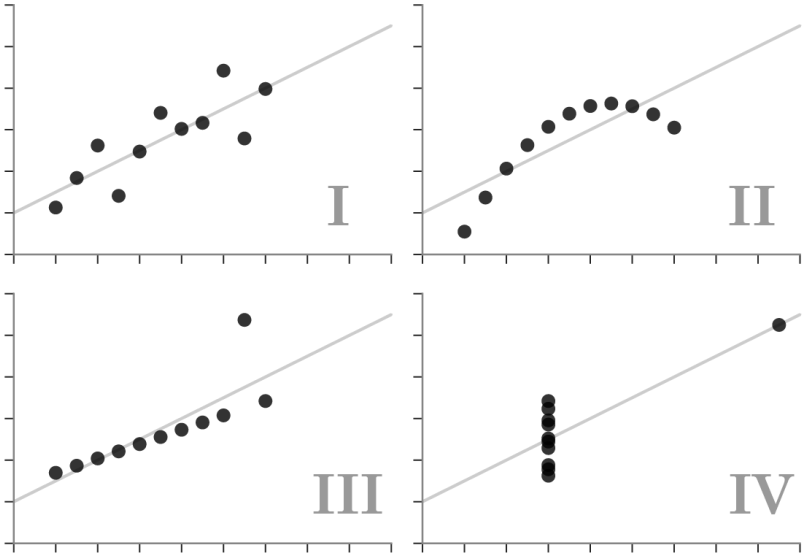

Unstructured Quartet
Each dataset here also has the same summary statistics. However, they are not *clearly different* or *visually distinct*.

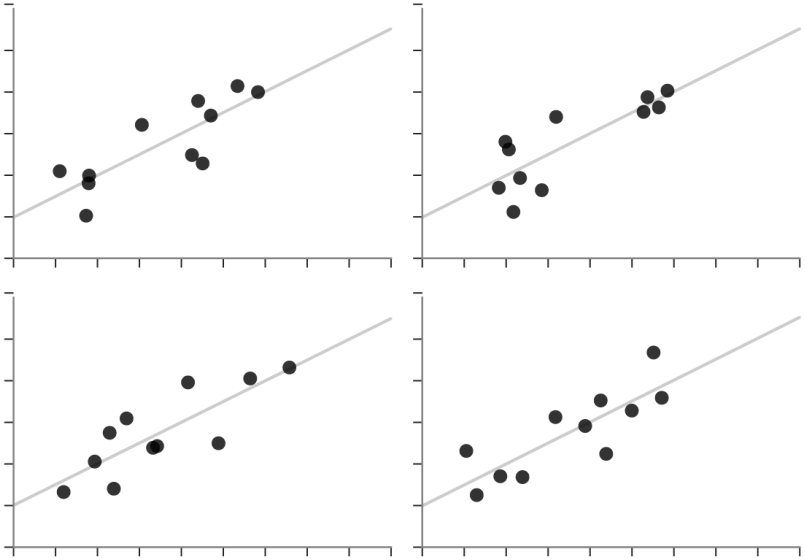

- Regarder l'histogramme et le nuage de points est toujours une bonne idée