

Analyse de la rémunération des joueurs de la Major League Baseball

Anh Minh Ho, Bruno Meler, Mohamed Aziz Mrad

6 avril 2026

1 Introduction & Problématique

Ce travail porte sur l’analyse de la rémunération des joueurs de la Major League Baseball (MLB), avec pour objectif principal de déterminer dans quelle mesure les performances sportives influencent le salaire annuel des joueurs.

La problématique centrale consiste à modéliser de manière robuste la relation entre les statistiques de performance, qu’elles soient saisonnières ou de carrière, et le salaire, tout en gérant les complexités statistiques des données réelles.

Dans quelle mesure les joueurs de baseball des ligues majeures sont-ils rémunérés en fonction de leurs performances ?

2 Présentation de l’article

L’étude se base sur l’article “*A Critical Look at Some Analyses of Major League Baseball Salaries*” écrit en 1995 par Hoaglin et Velleman [1].

Cet article fait suite à un défi lancé à quinze groupes de statisticiens : ils devaient tous analyser les mêmes données sur les salaires du baseball pour essayer de comprendre comment ils sont calculés. L’idée des auteurs n’est pas de trouver une formule magique pour les salaires, mais de regarder comment les différents experts travaillent et quelles méthodes fonctionnent le mieux sur des données réelles.

L’article montre les avantages et les erreurs de certaines méthodes de calcul. Hoaglin et Velleman expliquent qu’il ne faut pas appliquer les formules mathématiques sans réfléchir. Ils insistent sur l’importance de bien explorer les données au début, de transformer les chiffres si nécessaire et de faire attention aux salaires très élevés qui peuvent fausser les résultats. En résumé, l’article sert de guide pour apprendre à construire un modèle solide et fiable malgré les difficultés du terrain.

3 Présentation de la base de données

Les données utilisées pour cette étude proviennent de sources officielles du baseball américain, regroupant les salaires de l’année 1987 et les performances sportives de la saison 1986.

Le fichier concerne 322 joueurs, principalement des frappeurs, pour lesquels on dispose de nombreuses informations chiffrées. Ces chiffres incluent les résultats récents, comme le nombre de coups sûrs ou de points marqués en 1986, mais aussi des statistiques sur l'ensemble de leur carrière pour mesurer leur régularité et leur expérience dans la ligue.

En plus des performances, la base de données contient des détails sur le contexte de jeu, comme l'équipe du joueur, sa position sur le terrain ou encore la ligue dans laquelle il évolue. L'une des particularités importantes de ces données est la grande différence entre les salaires : la plupart des joueurs gagnent des sommes moyennes, tandis qu'une petite minorité atteint des revenus très élevés. Cette caractéristique, ajoutée au fait que certaines informations de salaires sont manquantes, oblige à préparer et à transformer les données avant de pouvoir créer un modèle de calcul fiable.

4 Analyse descriptive & résultats

4.1 Analyse du jeu de données

Le jeu de données possède 28 variables dont 7 variables qualitatives. Après importation et retrait des lignes avec des valeurs manquantes, on obtient un tableau de 263 joueurs. Ce sont tous des hitters.

4.2 Analyse univariée : distribution salariale

L'examen de la variable "Salaire" (Salary_1987) est l'étape charnière de cette étude. Cette analyse préliminaire révèle une structure de marché très spécifique qui dicte la stratégie de modélisation.

4.2.1 Constat : Une asymétrie marquée (Histogramme)

L'observation directe de la distribution brute (voir Figure 1) montre une forme unimodale fortement asymétrique à droite.

- **Concentration** : La grande majorité des observations se situe dans les tranches de bas salaires.
- **Profil de décroissance** : La fréquence des salaires diminue de manière quasi exponentielle à mesure que les montants augmentent, créant une "longue traîne" vers les hautes valeurs.
- **Conséquence** : La moyenne (542.2k\$) est largement supérieure à la médiane (430.0k\$). Ce décalage confirme que quelques très hauts salaires tirent la distribution vers le haut, faussant ainsi la perception du "joueur typique".




FIGURE 1 – Histogramme des salaires

4.2.2 Analyse des Quartiles et détection des Outliers (Boxplot)

L'utilisation d'un Boxplot (voir Figure 2) permet de segmenter mathématiquement la population et d'isoler les valeurs atypiques :

- **Le Cœur du Marché (Écart Interquartile - IQR) :**
 - Q1 (25%) : 193 000 \$.
 - Q3 (75%) : 750 000 \$.
 - **Interprétation :** 50 % des joueurs gagnent entre ces deux montants. Cette zone représente la "classe moyenne" du championnat.
- **Le Seuil d'Outlier (Méthode de Tukey) :** $\text{Seuil} = Q3 + (1.5 \times \text{IQR}) = 1\,585\,500$ \$.
- **Résultat :** 11 outliers sont détectés (environ 3,4 % de l'effectif). Ces superstars perçoivent des salaires si élevés qu'ils ne suivent plus la logique statistique du reste du groupe. Dans un modèle linéaire brut, ils auraient un poids disproportionné et risqueraient de "casser" la précision des prédictions pour les 96,6 % restants.




FIGURE 2 – Boxplot des salaires

4.2.3 Le passage au Logarithme : Une nécessité corrective

Face à ces biais, l'application d'une transformation logarithmique permet :

- **Symétrisation de la distribution** : Le logarithme "écrase" les écarts aux extrémités supérieures. La distribution se rapproche alors d'une loi normale, condition optimale pour la validité des tests statistiques.
- **Stabilisation de la variance (Homoscédasticité)** : Dans les données brutes, la dispersion tend à augmenter avec le niveau de salaire. Le passage au Log stabilise cette variance, garantissant que le modèle est aussi précis pour un remplaçant que pour une star.
- **Réduction de l'influence des outliers** : En ramenant les millions à une échelle comparable, on réintègre les 11 outliers dans le corps principal de la distribution sans perdre l'information qu'ils contiennent.

4.2.4 Vers une modélisation linéaire cohérente

Le but ultime est de préparer la variable pour un modèle de régression.

- **Le changement de paradigme** : Sans le logarithme, le modèle chercherait une relation additive (ex : "+1 Hit = +500\$"). Avec le logarithme, le modèle devient multiplicatif. On n'étudie plus des dollars bruts, mais des variations relatives.
- **L'Élasticité** : Cela permet d'expliquer le salaire par les performances (Hits, Home Runs, etc.) sous forme d'élasticité. Par exemple : "+10% de Runs → +5,16% de




FIGURE 3 – Distribution des salaires bruts et après transformation logarithmique

salaire". Ce modèle correspond bien mieux à la réalité économique du sport, où les écarts de talent se paient de manière exponentielle.

5 Régressions et résultats

L'analyse descriptive ayant mis en évidence des corrélations significatives entre le $\log(\text{Salary})$ et plusieurs variables de performance, trois prédicteurs ont été retenus pour la modélisation : la longévité (*Longevity*), le nombre de coups sûrs en 1986 (*Hits_86*), et une variable construite, *Hits_per_year*, obtenue en divisant le total de coups sûrs de carrière par le nombre d'années d'expérience. Cette normalisation est nécessaire car les totaux bruts de carrière favorisent mécaniquement les joueurs les plus expérimentés : 500 coups sûrs en 3 ans n'est pas équivalent à 500 coups sûrs en 15 ans. *Hits_per_year* mesure ainsi la performance moyenne annuelle, indépendamment de l'ancienneté. Ces trois variables ont été testées individuellement dans des régressions simples, puis combinées dans un modèle multiple.

5.1 Régressions simples

Trois régressions simples ont été ajustées afin d'étudier l'effet individuel de chaque prédicteur. M1 interroge l'impact de l'expérience seule sur le salaire, M2 celui de la performance lors de la saison récente, et M3 celui de la performance moyenne sur l'ensemble de la carrière.

- M1 : $\log(\text{Salary}) = 5.173 + 0.1047 \times \text{Longevity}$ ($R^2 = 0.322$)
- M2 : $\log(\text{Salary}) = 4.821 + 0.0103 \times \text{Hits_86}$ ($R^2 = 0.263$)
- M3 : $\log(\text{Salary}) = 4.572 + 0.0151 \times \text{Hits_per_year}$ ($R^2 = 0.430$)

Les trois modèles sont statistiquement significatifs. M1 indique qu'une année supplémentaire d'expérience est associée à une augmentation d'environ 11% du salaire ($e^{0.1047} \approx 1.11$). M3 obtient le meilleur R^2 des trois (0.430), suggérant que la performance moyenne sur la carrière explique mieux le salaire que la performance d'une seule saison. Pris individuellement, ces modèles restent insuffisants : le plus performant n'explique que 43% de la variance salariale, ce qui motive la construction d'un modèle combiné.




FIGURE 4 – Relation entre $\log(\text{Salary})$ et chaque prédicteur (M1, M2, M3)

5.2 Régression multiple

Afin de combiner les trois dimensions identifiées, un modèle de régression multiple a été construit en intégrant simultanément Longevity, Hits_per_year et Hits_86 :

$$\log(\text{Salary}) = 3.993 + 0.0875 \times \text{Longevity} + 0.0065 \times \text{Hits_per_year} + 0.0066 \times \text{Hits_86}$$

Les trois prédicteurs sont statistiquement significatifs ($p < 0.001$). L'interprétation des coefficients est la suivante :

- **Longevity** ($\beta = 0.0875$) : chaque année d'expérience supplémentaire est associée à une augmentation d'environ 9.1% du salaire, toutes choses égales par ailleurs.
- **Hits_per_year** ($\beta = 0.0065$) : chaque coup sûr supplémentaire par année de carrière est associé à une hausse d'environ 0.6% du salaire.
- **Hits_86** ($\beta = 0.0066$) : chaque coup sûr supplémentaire en 1986 est associé à une hausse d'environ 0.7% du salaire.

La longévité demeure le prédicteur dominant, avec un coefficient nettement supérieur aux deux variables de performance, suggérant que l'expérience est davantage récompensée que la performance seule dans ce modèle (voir Figure 5).

5.3 Qualité d'ajustement

Le modèle M4 atteint un R^2 de 0.621 (R^2 ajusté = 0.617), soit une amélioration remarquable par rapport aux modèles simples. Le R^2 ajusté, qui pénalise l'ajout de prédicteurs inutiles, reste quasi identique au R^2 , confirmant que les trois variables contribuent chacune véritablement au modèle. Le tableau suivant résume la comparaison :




FIGURE 5 – Coefficients du modèle M4 avec intervalles de confiance à 95%

Modèle	Prédicteurs	R^2	R^2 ajusté
M1	Longevity	0.322	0.319
M2	Hits_86	0.263	0.260
M3	Hits_per_year	0.430	0.428
M4	Combiné	0.621	0.617

TABLE 1 – Comparaison des modèles

M4 explique 62.1% de la variance de $\log(\text{Salary})$, contre 43% pour le meilleur modèle simple. Le graphique prédit vs réel (voir Figure 6) confirme visuellement cet ajustement : les points se distribuent de façon cohérente autour de la droite de référence $y=x$, avec une dispersion résiduelle attendue pour des données salariales réelles. Ces résultats indiquent que les performances sportives, combinées à l'expérience, expliquent une part significative des écarts salariaux.




FIGURE 6 – Valeurs prédites vs réelles — Modèle M4 ($R^2 = 0.621$)

6 Tests & diagnostics

Les diagnostics présentés ici visent à vérifier que le modèle de régression repose sur des bases statistiques solides. Deux aspects sont examinés : la normalité des résidus et l'absence de structure systématique dans les erreurs.

6.1 Normalité des résidus

Après avoir ajusté un modèle, on obtient pour chaque joueur un résidu : l'écart entre son salaire réel et celui prédit par le modèle. Pour que les résultats du modèle soient fiables, ces résidus doivent se comporter de manière aléatoire et suivre approximativement une distribution normale. Deux outils permettent de le vérifier.

Le **Q-Q plot** compare la distribution des résidus à ce qu'elle serait si elle était parfaitement normale. Si les points suivent la droite rouge, les résidus sont normalement distribués et le modèle est fiable. S'ils s'en écartent aux extrémités, cela indique une asymétrie. Les Q-Q plots (voir Figure 7) montrent que M1 et M4 suivent bien la diagonale sur la majeure partie de leur étendue. M2 et M3 présentent des déviations plus marquées aux queues inférieures, révélant une légère asymétrie négative.

Le **test de Shapiro-Wilk** formalise cette vérification : H_0 stipule que les résidus sont normalement distribués. Appliqué aux résidus de M4, il donne $W = 0.9878$, $p = 0.0248$. H_0 est formellement rejetée au seuil $\alpha = 5\%$, ce qui signifie qu'une déviation statistiquement détectable existe. Cependant, $W = 0.9878$ est très proche de 1, valeur correspondant à une

normalité parfaite, ce qui indique que cette déviation est d'ampleur négligeable en pratique. Avec 263 observations, le test devient très sensible aux moindres écarts. Le Q-Q plot de M4 confirme visuellement cette conclusion : les résidus suivent la droite de référence de manière satisfaisante, à l'exception de quelques points aux extrémités.




FIGURE 7 – Q-Q plot des résidus

6.2 Homoscédasticité et structure des résidus

Le graphique des résidus vs valeurs ajustées (voir Figure 8) permet de détecter si le modèle commet des erreurs de manière systématique. Un bon modèle produit des résidus dispersés aléatoirement autour de zéro, sans motif particulier. Si une forme apparaît comme une courbe, un arc, un entonnoir, cela signifie que le modèle rate une structure dans les données. M1 présente une forme en arc prononcée : le modèle sous-estime les salaires intermédiaires et surestime les salaires élevés. Cela confirme que la relation entre Longevity et $\log(\text{Salary})$ n'est pas linéaire. Une droite seule ne suffit pas à capturer l'évolution salariale avec l'expérience. M2 présente la courbe de tendance la plus proche de zéro parmi les modèles simples, mais son R^2 de 0.263 reste le plus faible donc la linéarité des résidus ne compense pas le manque de pouvoir explicatif. M3 et M4 présentent des comportements similaires : une légère tendance décroissante aux valeurs élevées, sans structure systématique majeure sur l'ensemble de la plage.




FIGURE 8 – Résidus vs valeurs ajustées

6.3 Conclusion sur la validité du modèle

Les diagnostics confirment que M4 est le modèle le plus fiable. La déviation à la normalité détectée par Shapiro-Wilk est d'ampleur négligeable et n'invalide pas les conclusions. L'absence de structure systématique dans les résidus de M4 valide son utilisation pour répondre à la problématique.

7 Discussion & limites

Les résultats obtenus apportent des éléments de réponse concrets à la problématique. M4 explique 62,1% de la variance salariale, ce qui constitue un pouvoir explicatif satisfaisant pour des données réelles. Les performances sportives et l'expérience contribuent chacune significativement au salaire. On peut donc affirmer que les joueurs sont partiellement rémunérés en fonction de leurs performances, mais cette relation n'est pas totale.

Les 37,9% de variance inexpliquée reflètent des facteurs absents de l'analyse. La position sur le terrain n'est pas prise en compte. Un receveur et un voltigeur n'ont pas le même profil salarial même à performances égales. Le budget des franchises joue également un rôle : une

grande franchise dispose de moyens très différents d’une petite équipe, indépendamment des performances individuelles. Des facteurs contractuels comme le statut d’agent libre ou les clauses de performance influencent aussi directement la négociation salariale sans apparaître dans les données. Par ailleurs, les 59 valeurs manquantes sur `Salary_1987` ont conduit à travailler sur 263 joueurs au lieu de 322, ce qui peut introduire un biais si ces données ne sont pas manquantes de façon aléatoire.

Sur le plan méthodologique, les diagnostics ont montré que la relation entre `Longevity` et $\log(\text{Salary})$ n’est pas purement linéaire. M1 présentait une forme en arc dans ses résidus. Notre modèle traite cette relation comme linéaire, ce qui constitue une simplification. Hoaglin & Velleman (1995) suggéraient d’introduire un terme quadratique pour `Longevity` afin de mieux capturer cette non-linéarité, une piste qui n’a pas été explorée ici.

8 Conclusion

L’analyse descriptive a mis en évidence une distribution salariale fortement asymétrique, justifiant le recours à une transformation logarithmique. Les régressions simples ont confirmé que la longévité, les coups sûrs en 1986 et la performance moyenne de carrière sont chacun significativement associés au salaire. Le modèle multiple M4, combinant ces trois variables, atteint un R^2 de 0,621, soit 62,1% de la variance salariale expliquée, avec des diagnostics satisfaisants confirmant sa validité statistique.

Ces résultats permettent de répondre positivement, mais partiellement, à la problématique : oui, les performances sportives influencent le salaire, mais elles n’en sont pas le seul déterminant. La longévité, qui reflète davantage l’expérience que la performance pure, s’avère le prédicteur dominant. Les 37,9% de variance inexpliquée rappellent que des facteurs comme la position, le budget des franchises et les conditions contractuelles jouent également un rôle que les données disponibles ne permettent pas de capturer.

Références

- [1] Hoaglin, D. C., & Velleman, P. F. (1995). *A Critical Look at Some Analyses of Major League Baseball Salaries*.